

基于小波变换和 AdaBoost 极限学习机的癫痫脑电信号分类

韩 敏*, 孙卓然

(大连理工大学 电子信息与电气工程学部, 辽宁 大连 116023)

(* 通信作者电子邮箱 minhan@dlut.edu.cn)

摘 要: 针对单一极限学习机(ELM)在癫痫脑电信号研究中分类结果不稳定、泛化能力差的缺陷,提出一种基于互信息(MI)的 AdaBoost 极限学习机分类算法。该算法将 AdaBoost 引入到极限学习机中,并嵌入互信息输入变量选择,以强学习器最终的性能作为评价指标,实现对输入变量以及网络模型的优化。利用小波变换(WT)提取脑电信号特征,并结合提出的分类算法对 UCI 脑电数据集以及波恩大学癫痫脑电数据进行分类。实验结果表明,所提方法相比传统方法以及其他同类型研究,在分类精度和稳定性上有着明显提高,并具有较好的泛化性能。

关键词: AdaBoost; 极限学习机; 小波变换; 互信息; 脑电信号分类

中图分类号: TP183 **文献标志码:** A

Epileptic EEG signals classification based on wavelet transform and AdaBoost extreme learning machine

HAN Min*, SUN Zhuoran

(Faculty of Electronic Information and Electrical Engineering, Dalian University of Technology, Dalian Liaoning 116023, China)

Abstract: Aiming at solving the problem of unstable predicted results and poor generalization ability when a single Extreme Learning Machine (ELM) was treated as a classifier in the research of automatic epileptic Electroencephalogram (EEG) signals classification, a classification method of AdaBoost ELM based on Mutual Information (MI) was put forward. The algorithm embedded the MI variable selection into AdaBoost ELM, regarded the final performance of the strong learner as evaluation index, and realized the optimization of input variables and network model. Wavelet Transform (WT) was used to extract the feature of EEG signal, and the proposed classification algorithm was used to classify the UCI EEG datasets and epileptic EEG datasets of the University of Bonn. The experimental results show that compared to traditional methods and other similar studies, the proposed method significantly has improvement in the classification accuracy and stability, and has better generalization performance.

Key words: AdaBoost; Extreme Learning Machine (ELM); Wavelet Transform (WT); Mutual Information (MI); Electroencephalogram (EEG) signals classification

0 引言

癫痫是一种常见的神经系统疾病,影响着全球1%~2%的人。癫痫发作的直接原因是大脑异常放电,具有突然性和短暂性脑功能紊乱的特征,致使患者的生活存在一定安全隐患^[1]。脑电信号是人脑的生理电信号,包含了大量的生理与病理信息,在临床医学和神经系统疾病诊断中起着重要的作用,因此广泛用于癫痫的诊断。随着计算机技术和人工智能理论的发展,脑电信号分类逐步成为很多学者研究的重点^[2]。

脑电信号分类包括信号的特征提取和样本分类。常用的脑电信号特征提取方法主要有时域分析、频域分析和时频分析等。时域分析是通过信号的时域变换得到相应特征,例如自回归模型^[3]等;频域分析是根据信号的频谱估计,将其分解成不同的组成频率进行谱分析,例如高阶谱分析^[4]等。然而这两种方法通常需要良好的预处理,对平稳性和信噪比要

求较高,且容易漏掉一些重要的异常变化。因此,时频分析得到广泛应用,它可以同时描述信号在不同时间和频率的能量密度和强度,如小波变换(Wavelet Transform, WT)^[5]等。小波变换具有多分辨特性,在时域和频域上都能很好地表征信号局部特征,对分析脑电信号这种非平稳信号具有至关重要的作用。基于上述分析,为了更好地表现脑电信号特征,本文使用小波变换对脑电信号进行特征提取。

将提取的特征输入到分类器可以得到需要的脑电信号分类信息。分类器性能对癫痫脑电信号分类结果有着举足轻重的作用。目前常用的分类器有决策树^[6]、人工神经网络^[7]、支持向量机(Support Vector Machine, SVM)^[8]等。作为神经网络的一种,近些年提出的极限学习机(Extreme Learning Machine, ELM)^[9]采取简单的线性回归方法进行求解,输入权值以及隐含层偏置随机设置,很好地克服了传统神经网络训练速度慢、容易陷入局部最优等的不足,在分类领域有着较好的应用价值。Song等^[10]利用极限学习机结合样本熵对脑

收稿日期: 2015-03-16; 修回日期: 2015-05-22。

基金项目: 国家自然科学基金资助项目(61374154); 中央高校基本科研业务费专项(DUT13JB08)。

作者简介: 韩敏(1959-),女,辽宁大连人,教授,博士,主要研究方向:复杂工业系统建模与控制、智能技术及优化算法; 孙卓然(1989-),男,辽宁锦州人,硕士研究生,主要研究方向:神经网络、脑电信号分类。

电信号分类; Chen 等^[9]将基于小波的非线性特征框架与极限学习机结合对癫痫脑电信号分类。

由于极限学习机输入权值向量和隐藏层偏置初始化随机,导致分类结果不稳定,具有一定的随机性。针对上述缺陷,本文提出基于互信息(Mutual Information, MI)的 AdaBoost 极限学习机算法,算法采用集成的思想,利用 AdaBoost 算法^[11]自适应提升特性,提升单个极限学习机,使其由弱学习器变成强学习器,提高结果的稳定性,增强分类器的泛化能力;同时将互信息^[12]变量选择嵌入到整体的学习过程中,形成封装式设计,利用变量选择方法的优势,在不改变数据本身的情况下,挑选出更有利于分类的特征信息,可以实现数据降维,去除冗余信息,提高分类结果精度。

1 基于互信息的 AdaBoost 极限学习机

1.1 极限学习机

极限学习机^[9, 13]是近些年提出的一种新的前馈神经网络,采取简单的线性回归方法有效地克服了传统神经网络基于梯度学习算法的缺陷,目前已经成功地应用在时间序列预测、数据分类等领域^[14]。

极限学习机的实现原理:假设数据的训练样本为 N 个 $\{(u_i, t_i) | i = 1, 2, \dots, N\}$, 其中输入向量 $u_i = [u_{i1}, u_{i2}, \dots, u_{ip}]^T \in \mathbf{R}^p$, 输出向量 $t_i = [t_{i1}, t_{i2}, \dots, t_{iq}]^T \in \mathbf{R}^q$ 。设 ELM 有 m 个隐含层节点 $g(\cdot)$ 为激活函数 $y = [y_1, y_2, \dots, y_N]^T \in \mathbf{R}^N$ 为网络输出,则可得对应的输入输出关系式为:

$$y_i = \sum_{j=1}^m \beta_j g(w_j^T u_i + b_j); i = 1, 2, \dots, N \quad (1)$$

其中: $w_j = [w_{j1}, w_{j2}, \dots, w_{jp}]^T \in \mathbf{R}^p$ 表示连接第 j ($j = 1, 2, \dots, m$) 个隐含层节点和输入节点的权值; $\beta_j = [\beta_{j1}, \beta_{j2}, \dots, \beta_{jq}]^T \in \mathbf{R}^q$ 表示连接第 j 个隐层节点和输出节点的权值, b_j 是第 j 个隐含层节点的偏置。

根据上述原理可知,极限学习机是弱学习器,初始权值随机,隐藏层节点数不固定,因此结果不稳定、泛化能力较差。针对上述不足,本文利用 AdaBoost 算法提升单一极限学习机的性能,使之成为强分类器,增强分类器稳定性与泛化性能。

1.2 互信息变量选择

通过特征提取方法得到的特征信息属性繁多,维数过高,很难在分类器中获得良好的分类效果。互信息能够衡量两个变量之间的相关性,选出相关性较大的变量,剔除相关性较小的变量,可以有效地降低数据维数,减小冗余信息。

互信息^[12]是指两个事件集合之间的相关性,两个离散随机变量 $F = (f_1, f_2, \dots, f_k)^T$ 与 $V = (v_1, v_2, \dots, v_d)^T$ 之间的互信息定义如下:

$$I(U, V) = \sum_u \sum_v p(u, v) \log \frac{p(u, v)}{p(u)p(v)} \quad (2)$$

其中: $p(u, v)$ 表示联合概率密度, $p(u)$ 和 $p(v)$ 表示边缘概率密度。互信息越大,变量 U 包含关于 V 的信息越多,即两变量的相关性越大。

把数据的各个特征作为输入,类标作为输出,利用式(2)计算出数据各个特征与类标间的相关性,使用最大相关最小冗余互信息^[12]方法找出其中相关性高的特征,剔除相关性小或者不相关的特征信息,这样能够尽可能地减小数据的冗余性,提高分类效果。

1.3 基于互信息的 AdaBoost 极限学习机

AdaBoost 算法^[12]是一种自适应提升方法,已在多种分类问题中得到了有效应用。其本质思想是看重错误划分的样本,通过迭代调整使得正确划分样本的权值被减少而错误划分样本的权值被加大,从而加大错误划分样本对分类器的影响,使得分类器加大对容易错误划分样本的注意力。利用 AdaBoost 算法提升单个 ELM,形成强学习器,从而提高预测精度及泛化性能;同时利用封装式设计思想将互信息变量选择嵌入到学习器中,按照相关性从大到小单步增加特征属性,剔除冗余信息,减小数据维数。基于互信息的 AdaBoost 极限学习机算法实现流程如图 1 所示,主要包括含变量选择、模型训练和测试三个部分。

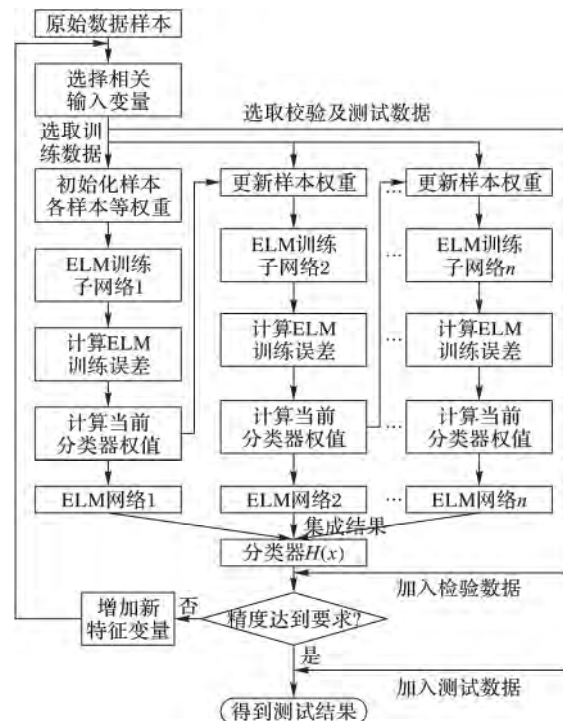


图 1 基于互信息的 AdaBoost 极限学习机算法流程

变量选择阶段:使用最大相关最小冗余互信息^[14]方法对输入数据进行处理,将其特征按照与类标的相关性由大到小排列,存储到矩阵 $Data$ 中,初始阶段从 $Data$ 中选择前 5 个特征组成数据矩阵 $Data1$;

训练阶段:在矩阵 $Data1$ 中随机选取部分数据组成输入训练样本集 $S = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$, 其中: x_i 是样本数据, y_i 为样本类标。设迭代次数为 T , 弱分类器为 $h(x)$, 则第 t 次迭代时样本 x_i 的分类结果为 $h_t(x_i)$ ($t \in T$), 能够得到 T 次迭代循环的分类结果矩阵如下:

$$A = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1N} \\ a_{21} & a_{22} & \dots & a_{2N} \\ \vdots & \vdots & & \vdots \\ a_{T1} & a_{T2} & \dots & a_{TN} \end{bmatrix}; a_{ij} = \begin{cases} 1, & h_i(x_j) = y_i \\ -1, & h_i(x_j) \neq y_i \end{cases} \quad (3)$$

其中: a_{ij} 表示第 i 次迭代第 j 个样本得到的分类结果正确与否, 如果分类结果正确为 1, 错误为 -1。算法训练详细步骤如下:

步骤 1 初始化: 每个样本的初始权值 $D_i(j) = 1/N$ ($j =$

1 2, ..., N; t = 1 2, ..., T)。

步骤2 Do For $t = 1 2, \dots, T$

a) 将样本输入到弱分类器 $h(x)$ 中(这里的 $h(x)$ 代表极限学习机)通过式(1)训练 ELM 得到网络参数、模型结构,同时得到相应的输出 $h_i(x_i)$ 。

b) 将输出与正确训练样本类标比较,得到训练分类结果 a_{ij} 。

c) 对所有 N 个样本的训练分类结果加权求和:

$$\text{Sum}(t) = \sum_{j=1}^N D_t(j) \times a_{ij} \quad (4)$$

如果 $\text{Sum}(t) > 0$, 说明本次结果有效, 继续进行下一步; 否则需要重新初始化权值返回到 a)。

d) 计算分类错误率:

$$\varepsilon_t = \left| \sum_{j=1}^N D_t(j) \times a_{ij} \right|; a_{ij} < 0 \quad (5)$$

e) 根据式(6)计算每次迭代训练的分类器权值:

$$\alpha_t = 2^{-1} \ln((1 - \varepsilon_t) / \varepsilon_t) \quad (6)$$

f) 根据式(7)更新样本权值:

$$D_{t+1}(j) = \frac{D_t(j)}{Z_t} \times \begin{cases} e^{-\alpha_t}, & a_{ij} = 1 \\ e^{\alpha_t}, & a_{ij} = -1 \end{cases} \quad (7)$$

其中: Z_t 为归一化因子, 是第 $t+1$ 次样本权值的总和;

End Loop

步骤3 循环结束后组合分类器:

$$H(x) = \text{sign} \left(\sum_{t=1}^T \alpha_t h_t(x) \right) \quad (8)$$

步骤4 根据校验数据检验分类器分类效果, 如果校验精度较上一次没有增加, 则停止循环, 此时强分类器 $H(x)$ 以及所选择的特征个数是最佳的; 如果校验精度相比上一次增加了, 则继续增加特征个数, 直到精度不增加为止。

测试阶段: 将测试数据放入组合分类器 $H(x)$ 中, 得到相应的测试分类结果。 $H(x)$ 是多个单极限学习机的有机组合, 利用加权方式对分类结果进行统计, 从而增强算法精度、稳定性以及泛化性能。

设 M 是样本原始变量个数, P 是经过互信息选择后的变量个数, N 为原始样本数, T 为基分类器个数, n 是极限学习机隐层节点数, 则所提算法计算复杂度为 $O(MP^2) + O(T \times (4Nn^2 + 8n^3))$ 。可以看出, 由于存在 T 个基分类器, 所提算法的计算复杂度要明显高于单一 ELM, 说明方法在寻求更好结果的同时牺牲了一定的计算时间。由于特征维数 M 及 P 相对较小, 而极限学习机的隐层节点数 n 很大, 所以数据经过互信息变量选择产生的计算复杂度 $O(MP^2)$ 要远小于分类器产生的复杂度 $O(T \times (4Nn^2 + 8n^3))$, 因此加入互信息变量选择对整体算法的复杂度影响很小。

2 仿真实验

为验证本文所提方法的有效性, 将本文所提基于互信息的 AdaBoost 极限学习机 (MI-AdaBoost-ELM) 分类方法用于 UCI 数据库 EEG 数据集以及波恩大学癫痫研究中心的脑电数据^[15]分类。UCI EEG 数据集包含醉酒者和正常人两组人群的脑电数据, 信号通过 64 个电极以 256 Hz 的频率采样得到, 每次实验记录 1 s 时长的脑电信号, 对每个对象进行 10 次实验。波恩大学癫痫中心数据库是在 2001 年建立, 并逐渐成

为脑电信号分类研究中的常用标准数据库。该数据库包含 5 组脑电信号 (A ~ E), 通过 173.61 Hz 频率采样得到, 每组有 100 段脑电信号, 每段信号包含 4097 个数据点。本文研究主要使用 A 组 (健康志愿者睁眼脑电信号)、D 组 (癫痫发作间期脑电信号) 和 E 组 (癫痫发作时脑电信号)。实验比较原始方法、其他一些方法与本文所提方法的分类效果, 实验结果以分类精度 (Accuracy) 和结果方差 (Variance) 表示。

2.1 脑电信号特征提取

脑电信号本质是多元混沌时间序列, 不能将其直接输入到分类器, 因此, 需要从脑电信号中找到一些描述量作为分类标准, 寻找这些描述量的过程就是脑电信号的特征提取, 本文使用小波变换对脑电信号进行特征提取。

小波变换^[5]是目前使用较多的一种信号分析工具, 它是傅里叶变换的拓展, 可以在时间和频域两个尺度上进行分析。设 $f(t)$ 为一维连续信号, 则 $f(t)$ 的连续小波变换 (有时也称为积分小波变换) 定义为:

$$WT_f(a, b) = |a|^{-1/2} \int_{-\infty}^{\infty} f(t) \psi\left(\frac{t-b}{a}\right) dt; a \neq 0 \quad (9)$$

其中: $\forall f(t) \in L^2(\mathbf{R})$, t 为时间变量; a 为伸缩因子 (又称尺度因子); b 为移位因子; $\psi(t)$ 为基本小波 (或母小波), 通过尺度伸缩 a 和平移 b 生成。

脑电信号属于非平稳信号, 它在时间上是离散的采样信号, 因此在使用计算机处理实际信号时常采用离散小波变换^[16]。图2描述了离散小波变换对信号进行多尺度分解的过程。 $x(n)$ 表示输入的一维离散信号, $g(n)$ 本质上是一个高通数字滤波器, 通过 $g(n)$ 可以得到一个详细信号 D1, 代表信号的高频分量; $h(n)$ 本质上是一个低通数字滤波器, 通过 $h(n)$ 可以得到一个逼近信号 A1, 代表信号的低频分量。对逼近信号 A1 再次进行分解可以得到 D2 和 A2, 以此类推。每个信号得到相应的小波系数, 该小波系数能够很好地反映出信号特点, 因此通常将小波系数作为脑电信号的特征分量。




图2 离散小波分解流程

由于本文使用的数据在 30 Hz 以上没有有用的频率部分, 所以本文采用 5 级小波分解将脑电信号分成详细信号 D1 ~ D5 以及逼近信号 A5。由于 Daubechies 4 (DB4) 良好的光滑特性, 使得它可以更好地检测到脑电信号的变换, 因此本文使用 DB4 作为小波函数的小波基。因为小波系数数量较多, 信息过于复杂, 所以采用统计特征的方法对小波系数进行整合。本文对脑电信号特征提取的详细步骤如下所示 (以波恩大学脑电数据为例):

步骤1 将信号以 1024 个采样点为一段截取, 得到每组共计 400 段信号。

步骤2 对信号预处理, 使用差分及平稳化方法, 如式 (10)、(11):

$$y_t = x_{t+1} - x_t \quad (10)$$

$$z_t = (y_t - y_{\min}) / (y_{\max} - y_{\min}) \quad (11)$$

步骤3 对每一段信号利用 DB4 小波进行 5 级小波分解, 得到相应的小波系数 (设其中第 i 个频带的小波系数为一维

向量 $N_i = (n_1 \ n_2 \ \cdots \ n_p)^T \in \mathbf{R}^p$ 。

步骤 4 计算每个频带小波系数绝对值的平均值(c_i):

$$c_i = \sum_{k=1}^p n_k / p \quad (12)$$

步骤 5 计算每个频带小波系数平均功率(W_i):

$$W_i = \sum_{k=1}^p n_k^2 / p \quad (13)$$

步骤 6 计算每个频带小波系数标准差(S_i):

$$S_i = \sqrt{\frac{1}{p} \sum_{k=1}^p (n_k - u_i)^2} \quad (14)$$

步骤 7 邻近小波系数绝对均值的比(Q_i):

$$Q_i = u_{i+1} / u_i \quad (15)$$

式(12)和(13)计算得到的特征表示信号的频率分布,式(14)和(15)计算得到的特征表示频率分布的变化,使用这些统计特征来描述信号的特点。经过小波变换以及统计特征整合后得到每组信号得到数据大小为 400×22 。

2.2 脑电信号分类

2.2.1 UCI 数据库 EEG 数据集分类实验

利用 2.1 节中脑电信号特征提取方法得到共计 320 个样本(160 个正常人,160 个醉酒者)。选取 200 个样本作为训练样本,其余作为测试样本。每组实验进行 50 次,结果取 50 次平均值,其中 ELM 隐藏层节点数均设置为 27,基分类器设置为 15 个。表 1 为各种方法在该数据集中的分类结果。

表 1 不同方法在 UCIEEG 数据集中的分类结果

分类器	分类精度	结果方差
ELM ^[9]	0.828 7	9.3E-04
SVM ^[8]	0.816 7	2.8E-04
Bagging ^[17]	0.847 0	1.1E-04
AdaBoost ^[17]	0.843 2	1.2E-04
MI_AdaBoost_ELM	0.868 5	2.3E-04

从实验结果可知,本文所提方法在对 UCI_EEG 数据二分类实验中,分类精度(86.85%)优于其他四种方法,说明该方法具有较好的分类效果。同时方法的方差为 E-04 数量级,说明方法具有较好的稳定性,单次分类波动较小,分类结果的可信度较高。

2.2.2 波恩大学癫痫研究中心脑电数据分类实验

根据 2.1 节中讲述的特征提取步骤,对 A、D、E 三组信号进行处理,每组得到 400 个数据样本。利用本文所提 MI_AdaBoost_ELM 方法对样本进行分类,在二分类(A/E)和多分类(A/D/E)实验中对比了不同方法的分类效果。在二分类实验中,随机抽取 600 个样本作为训练样本,其余作为测试样本,每组实验进行 50 次,结果取 50 次平均值,其中 ELM 隐藏层节点数均设置为 110,基分类器设置为 15 个;在多分类实验中,随机抽取 900 个样本作为训练样本,其余作为测试样本,每组实验进行 50 次,结果取 50 次平均值,其中 ELM 隐藏层节点数均设置为 160,基分类器设置为 15 个。表 2 和表 3 为各种方法在不同分类问题中的分类结果。

从表 2、3 数据可以看出,无论是在二分类还是多分类问题中,本文提出的 MI_AdaBoost_ELM 方法分类精确度都明显高于原始的 ELM 方法、SVM、Bagging 以及 AdaBoost 方法,同时在方差上也有着明显的提高,说明了方法在有着较好精确

度的同时有着很好的稳定性。由于本文采用的是强分类器,其稳定性要明显由于单一的弱分类器,同时将互信息变量选择封装到分类器中,可以实现分类器自主选择最优的分类特征,达到更好的分类结果。并且在不同的分类问题实验均取得较好的效果,表明方法还具有较强的泛化性能。

表 2 不同方法在二分类问题(A/E)中的分类结果

分类器	分类精度	结果方差
ELM ^[9]	0.946 3	2.96E-04
SVM ^[8]	0.935 0	1.13E-04
Bagging ^[17]	0.950 7	1.67E-04
AdaBoost ^[17]	0.971 6	6.88E-05
MI_AdaBoost_ELM	0.983 8	2.61E-05

表 3 不同方法在多分类问题(A/D/E)中的分类结果

分类器	分类精度	结果方差
ELM ^[9]	0.910 3	2.67E-04
SVM ^[8]	0.913 3	1.32E-04
Bagging ^[17]	0.912 9	1.20E-04
AdaBoost ^[17]	0.941 6	3.96E-05
MI_AdaBoost_ELM	0.960 5	1.87E-05

为了更好地检验分类器性能,计算 50 次实验中某一次的混淆矩阵(该次实验分类精确度与 50 次平均值接近),如表 4 所示。

表 4 A/D/E 分类实验混淆矩阵

类别		实际值		
		Set A	Set D	Set E
预测值	Set A	100	4	5
	Set D	0	96	1
	Set E	0	1	94
PA/%		100	96	94

PA 描述了样本集中每个类型数据被正确分类的比率,由表 4 可知,数据集 A 的正确率高达 100%,说明对正常人的分类十分准确。癫痫发作间期与发作期的分类正确率分别为 96% 和 94%,说明方法对相应信号的分类存在一定的误分类,将信号误分到正常人中较多,说明容易将该类信号看作正常信号处理。即便如此,方法达到的分类正确率也十分可观,基本能正确地对类别作出区分,对于癫痫疾病的诊断具有可靠的辅助决策作用。




图 3 各种方法在不同隐层节点数下的分类精度

ELM 隐藏层节点数往往影响着预测精度,为了证明本文所提方法在不同隐藏层节点下的预测性能,实验比较了各个方法在不同 ELM 隐层节点数下的预测精度。实验数据集采用 A、D、E 三组,使用表 2 中的四种考虑极限学习机隐层节点数的方法对数据进行多分类实验。如图 3 所示,实验结果表

明不同隐藏层节点数下,本文所提方法 MI_AdaBoost_ELM 的预测精度均高于其他方法;同时可以看出本文所提方法在局部范围内精度变化最小,趋势也较为平稳,数值保持在 0.955~0.965,说明了方法的稳定性以及良好的泛化性能。

各个分类算法对波恩大学脑电数据分类的运行时间如表 5 所示。可以看出,ELM 的速度最快,运行时间远小于其他三种集成算法。这是因为集成算法在增加基分类器后相当于多个 ELM 串行计算,耗时明显增加。虽然相对于 ELM,本文所提算法的运行时间较长,但 1 s 的运行时间对于实际应用情况是可以忽略的,而分类精度的明显提高有利于辅助疾病诊断。

表 5 各个分类算法在 A/D/E 数据集上运行时间

分类器	运行时间/s
ELM ^[9]	0.083 2
Bagging ^[17]	1.200 4
AdaBoost ^[17]	1.198 2
MI_AdaBoost_ELM	1.218 0

在表 6 中给出了一些其他学者同类型的研究方法,与本文所提方法 MI_AdaBoost_ELM 在分类精度上的对比,可以看出,尽管大家对于相同的分类任务,使用的特征提取方法与分类器都不尽相同,但在分类精度作为最重要考察指标的分类问题中,本文所提方法得到的结果略好于其他同类型研究。

表 6 与其他同类型研究在 A/E 和 A/D/E 问题分类精度对比

分类任务	分类方法	特征提取方法	分类器	分类精度/%
A/E	Kannathal 等方法 ^[18]	信息熵	自适应神经网络模糊推理	92.22
	Subasi 方法 ^[16]	小波变换	混合专家系统	95.00
	Guo 等方法 ^[19]	小波能量	人工神经网络	95.20
	本文方法	小波变换	MI_AdaBoost_ELM	98.38
A/D/E	Chua 等方法 ^[20]	高阶谱+功率谱密度	高斯混合模型	93.11
	Übeyli 方法 ^[5]	小波变换	混合专家系统	93.17
	Übeyli 方法 ^[21]	李雅普诺夫指数	人工神经网络	95.00
	本文方法	小波变换	MI_AdaBoost_ELM	96.05

3 结语

单一极限学习机实现癫痫脑电信号分类时易出现结果随机、不稳定的问题,本文使用 AdaBoost 提升了单一极限学习机的分类性能,形成强学习器,并利用互信息进行变量选择,采取封装式设计思路,不断增加相关特征,最终得到最合理的特征维度。使用小波变换提取脑电信号的分类特征,结合所提方法实现了脑电信号的自动分类。从实验结果可以看出,所提方法能够准确地区分不同情况的脑电信号,相比 ELM 虽然牺牲了一定时间,但是具有较高的分类精度、较强的稳定性及较好的泛化性能。实验结果可信性高,能够高效地完成癫痫脑电信号的分类任务,为医生诊断病人病情提供辅助决策。

参考文献:

[1] YAO W, LIU T, DAI J, *et al.* Multiscale permutation entropy analysis of electroencephalogram [J]. *Acta Physica Sinica*, 2014, 63 (7): 78704–78704. (姚文坡, 刘铁兵, 戴加飞, 等. 脑电信号的多尺度排列熵分析[J]. *物理学报*, 2014, 63 (7): 78704–

078704.)

- [2] FU K, QU J, CHAI Y, *et al.* Classification of seizure based on the time-frequency image of EEG signals using HHT and SVM [J]. *Biomedical Signal Processing and Control*, 2014, 13: 15–22.
- [3] LI P, WANG X, LI F, *et al.* Autoregressive model in the L_p norm space for EEG analysis [J]. *Journal of Neuroscience Methods*, 2015, 240: 170–178.
- [4] CHUA K C, CHANDRAN V, ACHARYA U R, *et al.* Analysis of epileptic EEG signals using higher order spectra [J]. *Journal of Medical Engineering & Technology*, 2009, 33(1): 42–50.
- [5] ÜBEYLI E D. Wavelet/mixture of experts network structure for EEG signals classification [J]. *Expert Systems with Applications: An International Journal*, 2008, 34(3): 1954–1962.
- [6] HU H-W, CHEN Y-L, TANG K. A novel decision-tree method for structured continuous-label classification [J]. *IEEE Transactions on Cybernetics*, 2013, 43(6): 1734–1746.
- [7] ZHANG G P. Neural networks for classification: a survey [J]. *IEEE Transactions on Systems, Man, and Cybernetics, Part C: Applications and Reviews*, 2000, 30(4): 451–462.
- [8] LI G, WANG W, ZHANG S. Application of SVM in EEG signal classification [J]. *Journal of Computer Applications*, 2006, 26(6): 1431–1433. (李钢, 王蔚, 张胜. 支持向量机在脑电信号分类中的应用[J]. *计算机应用*, 2006, 26(6): 1431–1433.)
- [9] CHEN L, ZHANG J, ZOU J, *et al.* A framework on wavelet-based nonlinear features and extreme learning machine for epileptic seizure detection [J]. *Biomedical Signal Processing and Control*, 2014, 10: 1–10.
- [10] SONG Y, ZHANG J. Automatic recognition of epileptic EEG patterns via extreme learning machine and multiresolution feature extraction [J]. *Expert Systems with Applications*, 2013, 40(14): 5477–5789.
- [11] CAO Y, MIAO Q, LIU J, *et al.* Advance and prospects of AdaBoost algorithm [J]. *Acta Automatica Sinica*, 2013, 39(6): 745–758. (曹莹, 苗启广, 刘家辰, 等. AdaBoost 算法研究进展与展望[J]. *自动化学报*, 2013, 39(6): 745–758.)
- [12] CANG S, YU H. Mutual information based input feature selection for classification problems [J]. *Decision Support Systems*, 2012, 54(1): 691–698.
- [13] ZHANG X, XU X, LING Z, *et al.* Seizure detection based on max-relevance and min-redundancy criteria and extreme learning machine [J]. *Journal of Computer Applications*, 2014, 34(12): 3614–3617. (张新静, 徐欣, 凌至培, 等. 基于最大相关和最小冗余准则及极限学习机的癫痫发作检测方法[J]. *计算机应用*, 2014, 34(12): 3614–3617.)
- [14] WANG X, HAN M. Multivariate chaotic time series prediction based on extreme learning machine [J]. *Acta Physica Sinica*, 2012, 61(8): 97–105. (王新迎, 韩敏. 基于极端学习机的多变量混沌时间序列预测[J]. *物理学报*, 2012, 61(8): 97–105.)
- [15] ANDRZEJAK R G, LEHNERTZ K, MOMANN F, *et al.* Indications of nonlinear deterministic and finite-dimensional structures in time series of brain electrical activity: dependence on recording region and brain state [J]. *Physical Review E*, 2001, 64(6): 061907.
- [16] SUBASI A. EEG signal classification using wavelet feature extraction and a mixture of expert model [J]. *Expert Systems with Applications*, 2007, 32(4): 1084–1093. (下转第 2709 页)

线性结构使其具有强大的特征表达能力和对复杂任务的建模能力; 基于 SAE 的水体提取模型通过无监督逐层训练为网络提供了更为合适的初始值, 通过隐藏层对原始输入的一步步抽象表示, 来学习原始输入的数据结构, 找到更有用的特征, 充分发掘遥感图像空间等方面的规律, 并且通过有监督微调进一步确定了较优的网络模型, 从而最终提高了水体提取的准确率。

4 结语

本文通过堆叠稀疏自编码器来构建 SAE 深度网络模型, 自编码器设定网络的输出值与输入值相同, 通过捕捉可以代表输入数据的最重要的因素来尽可能复现输入信号, 从而找到可以代表原信息的主要成分。本文使用的基于 SAE 的水体提取模型能自动发掘遥感数据所蕴含的空间等方面的规律, 无需进行复杂的光谱特征分析与特征选取, 进而提高水体提取的准确率和自动化程度。但是利用 SAE 模型提取水体时耗时较长, 提取效率有待提高, 下一步尝试构建深层模型的并行化框架和寻找训练加速的方法。

参考文献:

- [1] LU J, LI S. Improvement of the techniques for distinguishing water bodies from TM data [J]. *Remote Sensing of Environment*, 1992, 7(1): 17–23. (陆家驹, 李士鸿. TM 资料水体识别技术的改进[J]. *环境遥感*, 1992, 7(1): 17–23.)
- [2] ZHANG M. Extracting water body information with improved model of spectral relationship in a higher mountain area [J]. *Geography and Geo-Information Science*, 2008, 24(2): 14–16. (张明华. 用改进的谱间关系模型提取极高山地区水体信息[J]. *地理与地理信息科学*, 2008, 24(2): 14–16.)
- [3] YANG S, XUE C, LIU T, *et al.* A method of small water information automatic extraction from TM remote sensing images [J]. *Acta Geodaetica et Cartographica Sinica*, 2010, 39(6): 611–617. (杨树文, 薛重生, 刘涛, 等. 一种利用 TM 影像自动提取细小水体的方法[J]. *测绘学报*, 2010, 39(6): 611–617.)
- [4] DENG J, WANG K, LI J, *et al.* Study on the automatic extraction of water body information from SPOT-5 images using decision tree [J]. *Journal of Zhejiang University: Agriculture and Life Sciences*, 2005, 31(2): 171–174. (邓劲松, 王珂, 李君, 等. 决策树方法从 SPOT-5 卫星影像中自动提取水体信息研究[J]. *浙江大学学报: 农业与生命科学版*, 2005, 31(2): 171–174.)
- [5] Mc FEETERS S K. The use of the Normalized Difference Water Index (NDWI) in the delineation of open water feature [J]. *International Journal of Remote Sensing*, 1996, 17(7): 1425–1432.
- [6] XU H. A study on Information extraction of water body with the Modified Normalized Difference Water Index (MNDWI) [J]. *Journal of Remote Sensing*, 2005, 9(5): 589–595. (徐涵秋. 利用改进的归一化差异水体指数(MNDWI)提取水体信息的研究[J]. *遥感学报*, 2005, 9(5): 589–595.)
- [7] YANG B, LIU Z, XING Y, *et al.* Remote sensing image classification based on improved BP neural network [C]// *Proceedings of the 2011 International Symposium on Image and Data Fusion*. Piscataway: IEEE, 2011: 1–4.
- [8] WANG J, HE J. New algorithm of remote sensing image classification based on K-type support vector machine [J]. *Journal of Computer Applications*, 2012, 32(10): 2832–2835. (王静, 何建农. 基于 K 型支持向量机的遥感图像分类新算法[J]. *计算机应用*, 2012, 32(10): 2832–2835.)
- [9] YANG Y, XU L. Remote sensing image classification using layer-to-layer feature associative conditional random field [J]. *Journal of Computer Applications*, 2014, 34(6): 1741–1745. (杨耘, 徐丽. 基于分层条件特征关联条件随机场的遥感图像分类[J]. *计算机应用*, 2014, 34(6): 1741–1745.)
- [10] YANG W, YANG M, QI H. Water body extracting from TM image based on BPNN [J]. *Science of Surveying and Mapping*, 2012, 37(1): 148–150. (杨文亮, 杨敏华, 祁洪霞. 利用 BP 神经网络提取 TM 影像水体[J]. *测绘科学*, 2012, 37(1): 148–150.)
- [11] CHENG C, WEI Y, NIU Z. Water body extraction based on decision tree and ETM+ imagery: a case study of Poyang lake region [J]. *Remote Sensing Information*, 2012, 27(6): 49–56. (程晨, 韦玉春, 牛志春. 基于 ETM+ 图像和决策树的水体信息提取——以鄱阳湖周边区域为例[J]. *遥感信息*, 2012, 27(6): 49–56.)
- [12] CHEN J, LIU S, WANG C, *et al.* Research on urban water body extraction using knowledge-based decision tree [J]. *Remote Sensing Information*, 2013, 28(1): 29–33. (陈静波, 刘顺喜, 汪承义, 等. 基于知识决策树的城市水体提取方法研究[J]. *遥感信息*, 2013, 28(1): 29–33.)
- [13] YU K, JIA L, CHEN Y, *et al.* Deep learning: today, and tomorrow [J]. *Journal of Computer Research and Development*, 2013, 50(9): 1799–1804. (余凯, 贾磊, 陈雨强, 等. 深度学习的昨天、今天和明天[J]. *计算机研究与发展*, 2013, 50(9): 1799–1804.)
- [14] LYU Q, DOU Y, NIU X, *et al.* Remote sensing image classification based on DBN model [J]. *Journal of Computer Research and Development*, 2014, 51(9): 1911–1918. (吕启, 窦勇, 牛新, 等. 基于 DBN 模型的遥感图像分类[J]. *计算机研究与发展*, 2014, 51(9): 1911–1918.)
- [17] SKURICHINA M, DUIN R P W. Bagging, boosting and the random subspace method for linear classifiers [J]. *Pattern Analysis & Applications*, 2002, 5(2): 121–135.
- [18] KANNATHAL N, CHOO M L, ACHARYA U R, *et al.* Entropies for detection of epilepsy in EEG [J]. *Computer Methods and Programs in Biomedicine*, 2005, 80(3): 187–194.
- [19] GUO L, RIVERO D, SEOANE J A, *et al.* Classification of EEG signals using relative wavelet energy and artificial neural networks [C]// *CEC09: Proceedings of the first ACM/SIGEVO Summit on Genetic and Evolutionary Computation*. New York: ACM, 2009: 177–184.
- [20] CHUA K C, CHANDRAN V, ACHARYA R, *et al.* Automatic identification of epilepsy by HOS and power spectrum parameters using EEG signals: a comparative study [C]// *EMBS 2008: Proceedings of the 30th Annual International Conference of the IEEE Engineering in Medicine and Biology Society*. Piscataway: IEEE, 2008: 3824–3827.
- [21] ÜBEYLI E D. Analysis of EEG signals using Lyapunov exponents [J]. *Neural Network World*, 2006, 16(3): 257–273.

(上接第 2705 页)