

基于小波系数特征融合的小鼠癫痫脑电分类

肖文卿^{1,3}, 汪鸿浩², 詹长安¹

1. 南方医科大学 生物医学工程学院, 广州 510515

2. 南方医科大学附属南方医院, 广州 510515

3. 广州南方医大医疗设备综合检测有限责任公司, 广州 510515

摘要:采集癫痫小鼠模型在常态与致痫状态下的脑电信号以研究其癫痫脑电的自动分类。对经过噪声和伪迹消除预处理的脑电信号进行小波变换, 获得不同频率子带的小波系数, 对脑电信号及与癫痫特征波相关的小波系数提取相应的线性特征(标准差)和非线性特征(样本熵); 基于这些特征及其组合使用支持向量机分类器实现分类。实验发现基于小鼠脑电本身的标准差和样本熵的分类正确率分别为 59.10% 和 58.00%; 而融合各相关小波系数的标准差或样本熵, 分类正确率分别达到 86.60% 和 88.60%; 融合全部相关小波系数的线性特征和非线性特征后分类正确率为 99.80%。这些结果说明基于小波系数特征融合的分类算法性能有显著提升, 能有效实现小鼠癫痫脑电的自动分类。

关键词:癫痫小鼠模型; 小波变换; 特征融合; 支持向量机

文献标志码:A **中图分类号:**R318 **doi:**10.3778/j.issn.1002-8331.1903-0443

肖文卿, 汪鸿浩, 詹长安. 基于小波系数特征融合的小鼠癫痫脑电分类. 计算机工程与应用, 2019, 55(14): 155-161.

XIAO Wenqing, WANG Honghao, ZHAN Chang'an. Wavelet coefficient feature fusion based classification of mice epileptic EEG. Computer Engineering and Applications, 2019, 55(14): 155-161.

Wavelet Coefficient Feature Fusion Based Classification of Mice Epileptic EEG

XIAO Wenqing^{1,3}, WANG Honghao², ZHAN Chang'an¹

1. School of Biomedical Engineering, Southern Medical University, Guangzhou 510515, China

2. Nanfang Hospital of Southern Medical University, Guangzhou 510515, China

3. S.M.U. Medical Equipment Test Co., Ltd., Guangzhou 510515, China

Abstract: The Electroencephalogram (EEG) of mouse model of epilepsy in normal and epileptic status is collected to study the automatic classification of epileptic EEG. The noise- and artifact-attenuated EEG is wavelet-transformed, and the linear feature (standard deviation) and the nonlinear feature (sample entropy) are then extracted for the EEG signals and those wavelet coefficients related to the characteristic waveforms of epileptic EEG. Classification is implemented using support vector machine with above individual features and their combinations. The classification accuracy based on the standard deviation and sample entropy of EEG signals are 59.1% and 58.00%, respectively. The accuracy increases to 86.60% or 88.60%, when the standard deviations or sample entropies of relevant wavelet coefficients are used as input features. After combining both types of features, the classification accuracy is 99.80%. These results show that wavelet coefficient features fusion significantly improves the classification accuracy, achieving effective classification of mouse epileptic EEG.

Key words: epileptic mice model; wavelet transform; feature fusion; support vector machine

1 引言

癫痫(Epilepsy, EP)是一种以突然、反复发作的大脑内神经细胞群发生阵发性异常超同步电活动, 导致短

暂的大脑功能障碍为标志的慢性神经系统疾病。为了深入研究癫痫的发病机制, 大量的实验研究常常借助癫痫动物模型^[1-5]。戊四唑(Pentylenetetrazole, PTZ)药

基金项目:国家自然科学基金(No.61271154); 广州市高校创新创业教育项目(No.201709k28); 广州市科技计划项目(No.201804010282)。

作者简介:肖文卿(1992—), 男, 硕士研究生, 研究领域为生物医学信号处理; 汪鸿浩(1981—), 男, 副主任医师; 詹长安(1972—), 通讯作者, 男, 研究员, 研究领域为神经科学, 生物医学信号处理, 生物医学仪器等, E-mail: cznelab@smu.edu.cn。

收稿日期:2019-03-29 **修回日期:**2019-06-13 **文章编号:**1002-8331(2019)14-0155-07

CNKI 网络出版:2019-06-14, <http://kns.cnki.net/kcms/detail/11.2127.TP.20190613.1710.008.html>

物诱导的小鼠急性癫痫发作在症状、痫样放电图(EEG)等方面与人类的癫痫大致相似,在急性癫痫相关研究领域得到了世界广泛认可^[5-6]。

小鼠癫痫脑电的自动分类对发挥小鼠模型在癫痫研究方面的潜力十分重要。相关的癫痫脑电信号自动分类算法也有可能启发临床癫痫脑电的自动分类算法,从而有助于减轻医疗工作者的工作量。自20世纪60年代以来,研究人员对癫痫脑电提出了多种检测和分类方案^[7]。因为癫痫脑电的非平稳性,以时频特征为基础的方案较经典的时域或者频域分析更具潜力,可以同时时在时域和频域表征 EEG 的局部特性。Jahankhani 等人采用时-频分析方法中的离散小波变换(Discrete Wavelet Transform, DWT),将 EEG 分解,提取各层小波系数的最大值、最小值、方差等参数作为特征值,结合神经网络(Artificial Neural Network, ANN)分类器实现自动分类^[8],分类准确率达到98%。贺王鹏等人也利用小波子带重构信号的线性特征结合支持向量机(Support Vector Machine, SVM)获得98%的成功率^[9]。脑电的复杂性提示非线性特性在分类中的可能应用。李冬梅等人采用经验模式分解对 EEG 进行分解,提取主要本征模函数的样本熵特征值,输入 SVM 分类器中,实现癫痫脑电的自动分类,取得了90%的准确率^[10]。夏德玲等人利用经验模态分解获得信号的多层固有模态函数并提取各层的 Lempel-Ziv 复杂度作为特征,实现癫痫脑电的检测,取得了95.25%的分类准确率^[11]。过去研究也试图将非线性与线性特征进行融合,以提高分类正确率。张健钊等人对 EEG 进行离散 S 变换提取 EEG 各节律的系数,提取各节律的波动系数和 EEG 的排列熵构成特征向量,输入 AdaBoost 分类器进行自动分类,取得了98.13%的分类准确率^[12]。蔡冬梅等人将 EEG 的 Hurst 指数和带通滤波后三段频带的幅度均值结合作为特征向量,使用 SVM 分类器实现癫痫脑电的自动分类,取得了98.75%的分类准确率^[13]。这些研究在癫痫脑电的自动分类方面取得了十分有价值的进展,但是根据癫痫放电特征波(棘波、尖波、慢波)的时频特性^[14-15]选取相关小波系数,及其线性与非线性特征融合在癫痫脑电分类中的应用值得进一步研究。

本文提出基于小波系数特征融合的小鼠癫痫脑电自动分类方法。首先,对 EEG 进行离散平稳小波变换(Stationary Wavelet Transform, SWT),获得不同频率子带的小波系数,选取与癫痫脑电特性波(棘波、尖波、慢波)所在频率范围内的小波系数;分别提取其相关小波系数的线性特征和非线性特征;融合提取的线性特征和非线性特征构成特征向量,应用 SVM 方法实现小鼠癫痫脑电信号自动分类。作为对比,EEG 本身的线性特征和非线性特征,及这些特征的融合作为 SVM 的输入,分别计算分类性能。实验结果表明,基于相关小波系数的

线性与非线性特征融合的正常与癫痫脑电的分类正确率达到99.80%,远优于基于原始脑电信号特征的分类算法性能,取得了理想的分类效果。

2 方法

为了研究癫痫动物模型脑电的自动分类,本文选用 PTZ 诱发小鼠急性癫痫模型,记录致痫剂给药时间、小鼠行为、小鼠常态脑电和致痫状态脑电等数据。基于癫痫脑电的非平稳性(突发性、幅度异常)和频率分布特性,本文采用小波变换分解出特定的脑电成分并提取特征,用 SVM 对这些特征进行学习,实现小鼠癫痫脑电的自动分类。首先,按照致痫剂给药时间和小鼠行为对采集的小鼠脑电原始信号进行分段及预处理;其次,对分段脑电信号进行离散平稳小波变换,获得不同频率子带的小波系数,选取与癫痫脑电特性波(棘波、尖波、慢波)所在频率范围内的小波系数;分别提取预处理后的脑电信号及其相关的小波系数的相关线性特征(标准差值)和非线性特征(样本熵);最后,应用 SVM 分类器实现小鼠癫痫脑电信号自动分类。具体流程图如图1所示。




图1 小鼠癫痫脑电自动分类流程图

2.1 癫痫小鼠模型脑电采集及预处理

健康成年 C57/BL6 小鼠 9 只(年龄 7~8 周, 18~22 g, 由南方医科大学实验动物中心提供), 使用吸入式异氟烷(Isoflurane)对小鼠进行空气麻醉后, 将其头部固定于立体定位系统上, 切开头部皮肤, 利用立体定位仪对小鼠海马区 CA1 准确定位标记(前囟后 2.1 mm, 旁开 1.5 mm), 使用微型颅骨钻在相应位置磨穿颅骨后植入记录电极(硬膜下 1.3~1.5 mm), 对侧位置打磨头骨后贴上参考电极, 使电极与颅骨充分接触, 使用牙科水泥固定电极并缝合伤口, 小鼠耳垂连接接地电极。

实验采集数据时, 小鼠被置于金属网构建的法拉第电磁屏蔽笼中, 从而屏蔽外部环境干扰。脑电数据由 MP150 型 Biopac16 通道生理记录仪中 EEG100C 模块(Biopac Systems, Inc., Goeta, CA)采集, 高通滤波器截止频率设置为 0.5 Hz, 低通滤波器截止频率为 100 Hz, 采样频率为 500 Hz, 放大 5 000 倍。实验过程中, 首先采集小鼠正常状态下脑电数据; 然后使用致痫剂戊四唑 40 mg/kg 对小鼠腹腔注射制备癫痫小鼠急性模型, 采用 Smialowski 6 级记分法, 达到 IV 或 V 级为成功 PTZ 模型^[2]。采集癫痫小鼠模型在癫痫状态时的脑电数据; 同时, 使用摄像头实时监测小鼠癫痫行为及记录小鼠发作时间与状态。实验过程中记录致痫剂给药时间、实时监

测小鼠行为、采集小鼠常态脑电和致痫状态脑电等数据。

按照致痫剂给药时间和小鼠行为对采集的小鼠脑电原始信号进行分段及预处理。为避免 50 Hz 的工频干扰对后续数据分析的影响,本文采用 FIR (Finite Impulse Response) 数字滤波器对原始脑电数据进行滤除 50 Hz 的工频干扰。对照信号处理前后的功率谱,判断 50 Hz 的频率成分是否已有效滤除。同时,确认了采集到的信号能量仅限于系统设置的通带范围[0.5 100] Hz,无需做进一步基线漂移和低通滤波预处理。

2.2 离散小波变换

脑电信号是一种非平稳的复杂信号,小波变换能同时表征信号的时域和频域信息,具有多分辨率的特点^[16]。利用离散小波变换对信号进行多层小波分解,获得信号多种尺度的细节系数与近似系数。小波分解获得的各层小波系数可以表征特定频率子带内的信号性质,选取与癫痫放电特征波关联的小波系数的统计参数和复杂度参数作为癫痫脑电信号分类的特征分量。

图2展示的是离散小波变换对脑电信号进行小波分解的过程。 $X(n)$ 为一维的离散信号, $\phi(n)$ 是一个高通滤波器,通过 $\phi(n)$ 可获得信号的细节项系数 $D1$,表示信号的高频分量; $\varphi(n)$ 相当于一个低通滤波器,信号通过 $\varphi(n)$ 可获得一个近似项系数 $A1$,表示信号的低频部分。同理,进一步对近似信号 $A1$ 分解可获得 $D2$ 和 $A2$,迭代这个过程获得一系列的细节项和近似项。采用 Daubechies 小波函数中的 db20 作为小波基^[17],根据采样频率 500 Hz 和癫痫特征波的最低频带范围(慢波周期^[14-15]为 200~500 ms,对应 2~5 Hz),对 EEG 进行离散平稳小波变换七层小波分解,可获得各子带小波系数为 $D1$ 、 $D2$ 、 $D3$ 、 $D4$ 、 $D5$ 、 $D6$ 、 $D7$ 、 $A7$ 这八个频带(频率范围依次为:[125~250],[62.5~125],[31.25~62.5],[15.63~31.25],[7.81~15.63],[3.91~7.81],[1.95~3.91]和[0~1.95](单位:Hz))。




图2 离散小波分解过程

由小鼠癫痫脑电信号特性^[14-15]可知,小鼠癫痫脑电特征波中的棘波特点是幅值多在 100 μ V 以上,在 50 μ V 以下者称为短棘波或小棘波,周期在 80 ms 以内;尖波周期在 80~200 ms,波幅在 100~200 μ V,甚至高达 300 μ V 以上,常为负相波;慢波周期为 200~500 ms。棘波主要频段范围在 12.5 Hz 以上;尖波主要频段范围在 5~12.5 Hz;慢波主要频段范围在 2~5 Hz。因此,后续提取特征主要提取小波系数 $D3$ 、 $D4$ 、 $D5$ 、 $D6$ 和 $D7$ 这五层小波系数的相关特征进行分析。

2.3 特征提取

信号标准差(Standard Deviation, SD)是信号幅值偏离平均值的均方根。文献[18]表明小鼠正常状态下的脑电标准差低于癫痫状态下标准差。因此,提取小鼠在两种状态下脑电信号本身的标准差,以及相关小波系数的标准差,作为输入分类器的线性特征。

样本熵(Sample Entropy, SampEn)是由 Richman 提出的一种新的度量时间序列复杂度的方法^[19]。文献[20]发现癫痫发作时期脑电信号的复杂度下降。因此,样本熵值大小可以作为癫痫脑电分类的一种非线性特征。

假设初始数据为 $[x(1), x(2), \dots, x(N)]$, 其中 N 代表数据的长度。

将数据按顺序组成 m 维矢量:

$$X_m(i) = [x(i), x(i+1), \dots, x(i+m-1)] \quad (1)$$

式中 $1 \leq i \leq N-m+1$ 。

定义矢量 $X_m(i)$ 与 $X_m(j)$ 之间的距离是 $d[X_m(i), X_m(j)]$, 其为两者对应数据中最大差值,即:

$$d[X_m(i), X_m(j)] = \max |x(i+k) - x(j+k)| \quad (2)$$

式中 $1 \leq k \leq m-1, 1 \leq i, j \leq N-m+1, i \neq j$ 。

给定相应的阈值 $r(r \geq 0)$, 对于每一个 i 值 ($1 \leq i \leq N-m$), 计算统计 $d[X_m(i), X_m(j)] \leq r$ 的数目, 且运算出该数目与距离总数 $N-m-1$ 的比值, 记为 $B_i^m(r)$, 即:

$$B_i^m(r) = \frac{1}{N-m-1} \text{num}\{d[X_m(i), X_m(j)] \leq r\} \quad (3)$$

式中 $1 \leq j \leq N-m, i \neq j$ 。

计算其对所有 i 的平均值, 记作 $B^m(r)$, 即:

$$B^m(r) = \frac{1}{N-m} \sum_{i=1}^{N-m} B_i^m(r) \quad (4)$$

将维数加 1, 构成 $m+1$ 维的矢量。对于 $m+1$ 维矢量, 同样按照上面步骤, 并分别记作 $A_i^{m+1}(r)$ 和 $A^{m+1}(r)$ 。

理论上定义样本熵为:

$$\text{SamEn}(m, r) = \lim_{N \rightarrow \infty} \{-\ln(A^m(r)/B^m(r))\} \quad (5)$$

实际数据的 N 取有限值, 上式近似表示成:

$$\text{SamEn}(m, r) = -\ln\{A^m(r)/B^m(r)\} \quad (6)$$

SamEn 的值与嵌入维数 m 和阈值 r 的取值有关。一般情况下, 参数设置为 $m=1$ 或 2, $r=0.1SD \sim 0.25SD$, 其中 SD 为给定原始数据的标准差^[16,21]。本文选取参数 $m=2, r=0.2SD$, 提取小鼠在两种状态下脑电信号本身的样本熵, 以及相关小波系数的样本熵, 作为输入分类器的非线性特征。

2.4 SVM 分类器

SVM 是一种统计学习方法, 能够较好地处理小样本监督分类问题上, 并具有很好的泛化能力^[9,22]。为了实现癫痫和非癫痫脑电分类, 构建训练学习样本集 $D = \{(x_i, y_i)\}_{i=1}^m, y_i \in \{-1, 1\}$, 其中 x_i 为 d 维脑电特征, y_i 为类别标签 (-1 表示癫痫, 1 表示正常脑电), m 是信号

片段数量,即训练样本数。对于判别函数 $g(x)=w \cdot x+b$, 学习算法的目标是在特征空间寻找一个超平面,划分两类标签对应的特征,分类的超平面方程满足 $w \cdot x+b=0$, 其中, w 为权重系数, b 为偏置项。将最接近分类超平面的 EEG 样本的判别函数值归一化为 1, 即 $|g(x)|=1$ 。可计算出靠近超平面的两类支持向量中的点之间距离为 $\frac{2}{\|w\|}$ 。为了使两类支持向量中的点间隔最大化, 必

须使 $\|w\|^{-1}$ 最大化, 也就是 $\|w\|^2$ 最小化。采用构造拉格朗日函数, 引入乘子 $\alpha=(\alpha_1, \alpha_2, \dots, \alpha_m)$, 将上述问题转换成凸二次规划问题。从而求得线性判别函数:

$$f(x)=\operatorname{sgn}\left(\sum_{i=1}^m a_i^* y_i K(x, x_i)+b^*\right) \quad (7)$$

式中 m, a_i^*, b^* 分别代表支持向量个数, 支持向量系数和分类阈值。核函数 $k(x, x_i)$ 的形式主要包括多项式核函数、径向基函数、Sigmoid 函数^[21-25], 其中径向基函数具有较宽的收敛域, 并有研究表明, 基于径向基函数的 SVM 更适用于 EEG 信号的分类研究^[22-25]。因此本文选取径向基核函数作为 SVM 核函数。

2.5 分类性能评价

为了方便对分类学习算法性能进行综合评价, 本文采用了敏感性 (Sensitivity, SEN)、特异性 (Specificity, SPE) 和分类正确率 (Accuracy, ACC) 作为算法性能评价指标, 从而获得更稳定和可信的实验结果, 计算公式如下:

$$SEN=\frac{TP}{TP+FN} \times 100\% \quad (8)$$

$$SPE=\frac{TN}{TN+FP} \times 100\% \quad (9)$$

$$ACC=\frac{TP+TN}{TP+FP+TN+FN} \times 100\% \quad (10)$$

式中, TP (True Positive) 表示判断为阳性的阳性数据的个数, TN (True Negative) 表示判断为阴性的阴性数据的个数, FP (False Positive) 表示判断为阳性的阴性数据的个数, FN (False Negative) 表示判断为阴性的阳性数据的个数^[11, 22]。本文将正常状态时的脑电数据定义为阴性数据, 癫痫状态时的脑电数据定义为阳性数据。

3 实验结果与分析

实验选取正常脑电和癫痫脑电各 400 个片段样本, 每个片段长度为 1 000 个数据点 (2 s)。选取各脑电信号片段的 $D3$ 至 $D7$ 这五层小波系数, 提取脑电信号本身的线性特征 (标准差) 和非线性特征 (样本熵) 两类特征值, 以及小波系数 $D3$ 至 $D7$ 这五层小波系数的线性特征 (标准差值) 和非线性特征 (样本熵值)。采用非参数检验来分析上述小鼠正常状态与癫痫状态下的特征值之间的差异。以 $P<0.05$ 和 $P<0.01$ 表示两种不同级别的显著性差异。

图 3 是在正常状态和癫痫状态时小鼠 EEG 本身和五层小波系数的标准差值盒形图; 显示小鼠在正常状态和癫痫状态时期的本身 EEG 的标准差值与其小波系数 $D3$ 至 $D7$ 这五层小波系数的标准差值全部存在显著差别; 在正常状态下小鼠本身 EEG 以及相关小波系数的标准差值显著小于癫痫状态下的标准差值。于是, 在正常状态和癫痫状态时小鼠 EEG 本身和五层小波系数的标准差值适合作为癫痫脑电检测与分类的特征值。

图 4 是在正常状态和癫痫状态时小鼠 EEG 本身和

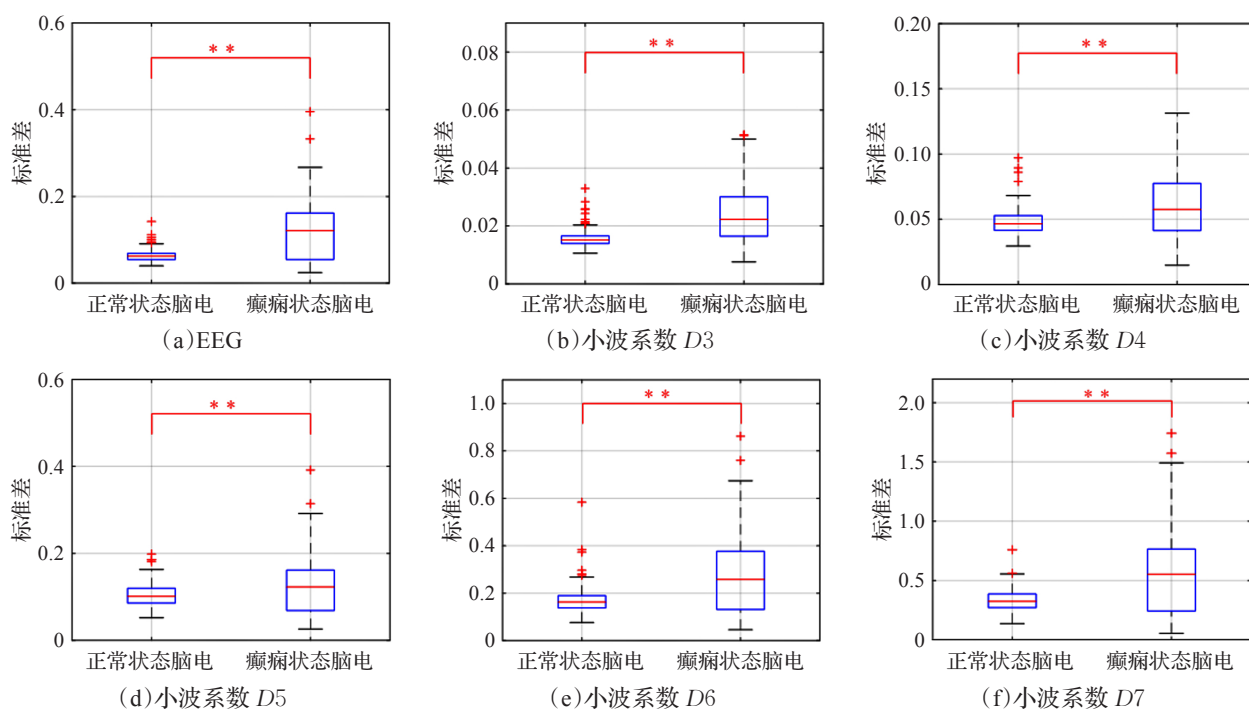


图3 在正常与癫痫状态下小鼠 EEG 及其小波分解系数 $D3 \sim D7$ 的标准差值比较

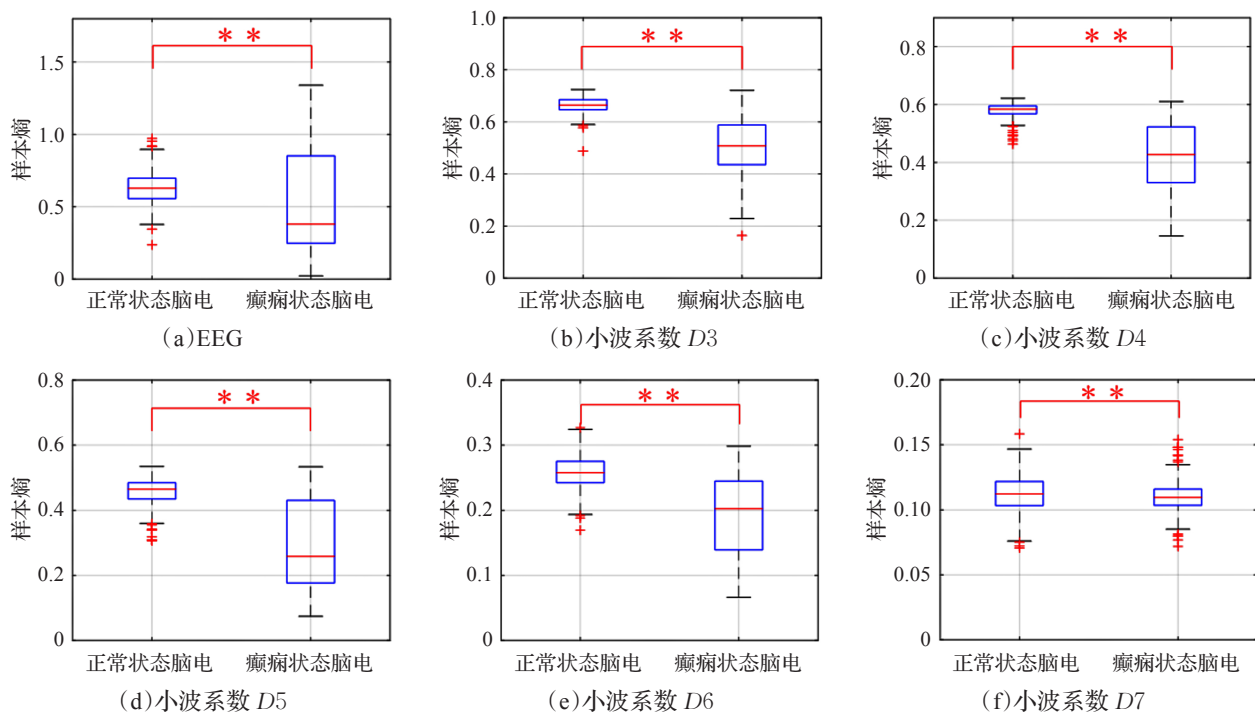


图4 在正常与癫痫状态下小鼠EEG及其小波分解系数D3~D7的样本熵比较

表1 不同小鼠的癫痫脑电SVM分类准确率 %

数据	以标准差为特征				以样本熵为特征			
	1号小鼠	2号小鼠	3号小鼠	本文方法	1号小鼠	2号小鼠	3号小鼠	本文方法
EEG信号	74.00	60.10	63.40	59.10	64.80	87.80	71.30	58.00
D3	81.00	80.30	76.90	62.10	87.50	96.00	88.80	83.30
D4	75.60	86.90	80.10	65.80	85.60	93.80	76.80	75.30
D5	74.60	79.40	85.50	72.10	81.60	89.90	82.40	77.80
D6	78.90	83.50	88.80	71.00	74.00	68.10	73.50	67.40
D7	80.90	74.10	86.00	69.80	69.50	80.50	80.80	58.60
D3~D7的特征融合	92.00	90.80	94.50	86.60	91.60	97.80	89.90	88.60

其五层小波系数的样本熵值盒形图;显示小鼠在正常状态和癫痫状态时其本身EEG信号和小波系数D3至D7这五层小波系数的样本熵值均显著区别。因此,提取小鼠本身EEG以及其小波系数D3至D7这五层小波系数的样本熵适合作为特征值输入分类器中实现自动分类。

表1展示的是不同小鼠基于标准差(或者样本熵)作为特征值的小鼠癫痫脑电SVM分类准确率。选取单只小鼠的正常脑电和癫痫脑电各400个片段样本(其中训练数据为300个样本,测试数据为100个样本),采用同样的方法运算出小鼠的分类准确率。实验表明:由于每只小鼠自己的癫痫脑电特性有所不同,提取单只小鼠本身EEG信号及其分解后五层小波系数的标准差值(或样本熵)作为单一特征向量进行癫痫脑电SVM分类准确率存在差异,且均高于综合多只小鼠样本的分类准确率。融合五层小波系数的标准差(或样本熵)作为特征向量的癫痫SVM分类准确率高于小鼠本身EEG以及任意一层小波系数的分类准确率。为了实验结果的正确性,采用不同小鼠的不同样本作为本实验的实验训练集与测试集,虽然相关的分类准确率会降低,但是消除

了不同小鼠的癫痫脑电特性差异,体现了实验数据的客观性与多样性。

表2显示的是不同训练模型对小鼠癫痫脑电分类的结果。选取实验小鼠总体样本中正常脑电和癫痫脑电各400个片段样本(其中训练数据为300个样本,测试数据为100个样本),对小鼠本身EEG及与癫痫脑电特征波相关的小波系数提取线性特征(标准差)和非线性特征(样本熵),输入SVM分类器中自动分类。实验结果表明:对小鼠EEG信号的标准差值作为单一特征向量进行癫痫脑电SVM分类,敏感性只有45.75%,总体准确率也只达到59.10%;以小鼠EEG本身的样本熵值作为单一特征向量进行癫痫脑电SVM分类,其敏感性只有46.00%,总体准确率也只有58.00%;但是,采用融合五层小波系数的标准差值构成特征向量进行癫痫脑电SVM分类,其准确率达到86.60%,敏感性达到了82.75%,特异性有90.50%;融合五层小波系数的样本熵值构成特征向量进行癫痫脑电SVM分类,其准确率达到88.60%,敏感性达到了80.25%,特异性也有97.00%。从而说明了融合五层小波系数的标准差或者

表2 基于不同特征值的小鼠癫痫脑电SVM分类结果

数据	以标准差为特征			以样本熵为特征			融合标准差和样本熵特征		
	敏感性	特异性	准确率	敏感性	特异性	准确率	敏感性	特异性	准确率
EEG信号	45.75	72.50	59.10	46.00	70.00	58.00	86.00	92.67	89.30
D3	46.00	78.25	62.10	73.75	92.75	83.30	100.00	97.67	98.80
D4	45.25	86.25	65.80	58.50	92.00	75.30	100.00	95.00	97.50
D5	57.00	87.25	72.10	59.00	71.50	77.80	99.67	95.67	97.70
D6	53.50	88.50	71.00	46.75	88.00	67.40	97.33	98.00	97.70
D7	57.50	82.00	69.80	79.50	37.75	58.60	92.00	94.33	93.20
D3~D7的特征融合	82.75	90.50	86.60	80.25	97.00	88.60	99.67	100.00	99.80

样本熵的值构成特征向量进行癫痫脑电SVM分类性能更优于小鼠EEG本身的标准差值或样本熵值为单一特征向量的分类性能,并且以各层小波系数的样本熵值或者标准差值作为单一特征向量的分类性能也明显比小鼠EEG本身的标准差值或者样本熵值作为单一特征向量的分类性能更好。

从表2融合标准差和样本熵两类特征值构成特征向量的小鼠癫痫脑电SVM分类结果中可以看出,融合任何一层小波系数的标准差和样本熵两种特征值作为特征向量的分类性能更优于单一特征向量的癫痫脑电分类性能;并且融合全部相关小波系数的标准差与样本熵作为特征向量进行分类,准确率达到99.80%,超过任一单一特征值的分类性能。

4 结束语

时频特征分析和机器学习方法在脑电信号自动分类问题中有着重要的应用。本文采用离散平稳小波变换分解EEG,获得不同的频率子带小波系数,选取与癫痫脑电特征波(棘波、尖波、慢波)所在频率范围内的小波系数;分别对预处理后的脑电信号及与癫痫脑电特征波相关的小波系数提取线性特征(标准差)和非线性特征(样本熵);应用SVM分类器对小鼠癫痫EEG进行自动分类,得到以下结论:

(1)提取小鼠EEG与癫痫特征波相关的小波系数的线性特征(标准差)和非线性特征(样本熵),癫痫与正常脑电的分类正确率均达到58.60%以上,高于以小鼠EEG本身的标准差或样本熵作为单一特征的分类正确率(分别为59.10%和58.00%)。说明这些小波系数能很好地表征脑电信号的动态特性,离散平稳小波变换是一种十分有效的时频分析工具。

(2)融合各相关小波系数的线性特征或非线性特征,分类正确率分别达到86.60%和88.60%,优于单一特征的分类性能,体现了多层小波系数间的特征融合在分类中的价值。

(3)融合任何一层小波系数的线性和非线性特征,分类性能较其单一的线性或非线性特征分类性能获得进一步提升。同时,融合全部相关小波系数的线性和非

线性特征后分类正确率达到了99.80%,能够有效实现小鼠癫痫脑电的自动分类。

本文提出基于小波系数特征融合和支持向量机的小鼠癫痫脑电信号的自动分类方案,能有效解决小鼠正常与癫痫脑电分类问题,可以启发临床癫痫脑电的自动分类算法研发,有助于提升医疗工作者的工作效率。下一步将进一步尝试其他特征的提取与融合,设计分类算法应用于人类癫痫脑电信号的自动分析。

参考文献:

- [1] Qing W H, Sidra T, Afzal A M, et al. Recording EEG in freely moving neonatal rats using a novel method[J]. Journal of Visualized Experiments, 2017, 123.
- [2] Sukhvir W, Kvan H, Lukasz S, et al. Epileptogenic effects of NMDAR antibodies in a passive transfer mouse model[J]. Brain, 2015, 138(11): 3159-3167.
- [3] Quang M T, Ashwin A, Min C, et al. Mouse epileptic seizure detection with multiple EEG features and simple thresholding technique[J]. Journal of Neural Engineering, 2017.
- [4] 陈小千, 封洲燕, 郭哲彬, 等. 癫痫模型中痫样棘波自动检测的新算法及其应用[J]. 生物医学工程学杂志, 2017, 34(4): 485-492.
- [5] 张永宁, 肖素希, 肖文, 等. 癫痫动物模型的研究进展[J]. 科教导刊, 2017, 19(7): 157-158.
- [6] Muhammad I N, Li S, Myeong O K. Maternal epileptic seizure induced by pentylentetrazol: apoptotic neurodegeneration and decreased GABA_{B1} receptor expression in prenatal rat brain[J]. Molecular Brain, 2009, 2(1): 1-11.
- [7] 张瑞, 宋江玲, 胡文凤. 癫痫脑电的特征提取方法综述[J]. 西北大学学报(自然科学版), 2016, 46(6): 781-788.
- [8] Jahankhani P, Kodogiannis V, Revett K. EEG signal classification using wavelet feature extraction and neural networks[C]//IEEE John Vincent Atanasoff 2006 International Symposium on Modern Computing (JVA'06), 2006: 52-57.
- [9] 贺王鹏, 杨琳, 王芳, 等. 基于TQWT的癫痫脑电信号的识别[J]. 生物医学工程研究, 2017, 36(4): 346-350.

- [10] 李冬梅,张洋,杨日东,等.经验模式分解与代价敏感支持向量机在癫痫脑电信号分类中的应用[J].生物医学工程研究,2017,36(1):33-37.
- [11] 夏德玲,孟庆芳,牛贺功,等.基于Lempel-Ziv复杂度和经验模态分解的癫痫脑电信号的检测方法[J].计算机物理,2015,32(6):709-714.
- [12] 张健钊,姜威,元辉,等.基于离散S变换和排列熵的癫痫脑电识别[J].生物医学工程学杂志,2017,34(5):681-686.
- [13] 蔡冬梅,周卫东,刘凯,等.基于Hurst指数和SVM的癫痫脑电检测方法[J].中国生物医学工程学报,2010,29(6):836-840.
- [14] 吴晓彬,郭影,邱天爽,等.B样条小波在提取脑电癫痫棘波中的应用[J].生物医学工程学杂志,2006,23(5):947-950.
- [15] 师梨,陈明静.基于小波包分解和遗传神经网络的癫痫识别[J].计算机工程与应用,2010,46(12):218-220.
- [16] 崔刚强,夏良斌,梁建峰,等.基于小波多尺度分析和极限学习机的癫痫脑电分类算法[J].生物医学工程学杂志,2016,33(6):1025-1038.
- [17] 徐长发,李国宽.实用小波方法[M].3版.武汉:华中科技大学出版社,2009:55-163.
- [18] Janjarsjitt S.Classification of the epileptic EEGs using the wavelet-based scale variance feature[J].International Journal of Applied Biomedical Engineering, 2010, 3(1): 19-25.
- [19] Richman J S, Moorman J R.Physiological time-series analysis using approximate entropy and sample entropy[J].Am J Physiol Heart Circ Physiol,2000,278(6).
- [20] 张健钊,姜威,贾晔.基于样本熵与小波包能量特征提取和Real AdaBoot算法的正常期、癫痫间歇与发作期的脑电自动检测[J].生物医学工程学杂志,2016,33(6):1031-1038.
- [21] 杨松,于凤芹.基于样本熵的语音/音乐识别[J].计算机工程与应用,2012,48(23):125-127.
- [22] 周志华.机器学习[M].北京:清华大学出版社,2015:121-145.
- [23] 奉国和.SVM分类核函数及参数选择比较[J].计算机工程与应用,2011,47(3):123-124.
- [24] 李明阳,陈万忠,张涛.基于DD-DWT和Log-Logistic参数回归的癫痫脑电自动识别[J].仪器仪表学报,2017,38(6):1368-1377.
- [25] Martis R J, Tan J H, Chua C K, et al.Epileptic EEG classification using nonlinear parameters on different frequency bands[J].Journal of Mechanics in Medicine and Biology,2015,15(3):1-20.

(上接第147页)

- [12] 邓强,杨燕,王浩.一种改进的多视图聚类集成算法[J].计算机科学,2017,44(1):65-70.
- [13] 苏辉,葛洪伟,张涛,等.基于视图相关因子的多视图数据竞争聚类算法[J].计算机工程与应用,2017,53(3):100-105.
- [14] Tekumalla L S, Rajan V, Bhattacharyya C.Vine copulas for mixed data: multi-view clustering for mixed data beyond meta-Gaussian dependencies[J].Machine Learning, 2017,106(9/10):1-27.
- [15] Nie F, Huang H, Cai X, et al.Efficient and robust feature selection via joint $\ell_{2,1}$ -norms minimization[C]//Proc of International Conference on Neural Information Processing Systems,2010:1813-1821.
- [16] Huang J, Nie F, Huang H, et al.Robust manifold non-negative matrix factorization[J].ACM Transactions on Knowledge Discovery from Data,2014,8(3):1-21.
- [17] Zhao N, Zhang L, Du B, et al.Robust dual clustering with adaptive manifold regularization[J].IEEE Transactions on Knowledge & Data Engineering,2017,29(11):2498-2509.
- [18] Xu C, Tao D, Geng B, et al.Ensemble manifold regularization[J].IEEE Transactions on Pattern Analysis and Machine Intelligence,2012,34(6):1227-1233.
- [19] Belkin M, Niyogi P.Laplacian eigenmaps and spectral techniques for embedding and clustering[C]//Proc of Advances in Neural Information Processing Systems, 2001:585-591.
- [20] 张田昊.数据降维算法研究及其应用[D].上海:上海交通大学,2008.
- [21] Hartigan J A, Wong M A.Algorithm AS 136:a K -means clustering algorithm[J].Journal of the Royal Statistical Society:Series C Applied Statistics,1979,28(1):100-108.
- [22] Shi J, Malik J.Normalized cuts and image segmentation[J].IEEE Transactions on Pattern Analysis and Machine Intelligence,2000,22(8):888-905.
- [23] Elhamifar E, Vidal R.Sparse subspace clustering:algorithm, theory, and applications[J].IEEE Transactions on Pattern Analysis and Machine Intelligence,2013,35(11):2765-2781.
- [24] Cai D, Chen X.Large scale spectral clustering via landmark-based sparse representation[J].IEEE Transactions on Cybernetics,2015,45(8):1669-1680.
- [25] Guan N, Liu T, Zhang Y, et al.Truncated Cauchy non-negative matrix factorization for robust subspace learning[J].IEEE Transactions on Pattern Analysis and Machine Intelligence,2018.