

基于局部均值分解和迭代随机森林的脑电分类

秦喜文^{a, b}, 郭宇^a, 董小刚^a, 郭佳静^a, 袁迪^a

(长春工业大学 a. 数学与统计学院; b. 研究生院, 长春 130012)

摘要: 为实现癫痫患者的脑电信号有效识别, 进而提高患者的生活质量, 针对脑电信号的非平稳、非线性特点, 提出一种基于局部均值分解和迭代随机森林相结合的脑电信号分类方法。首先利用局部均值分解将脑电信号分解成若干个乘积函数分量和一个残余分量, 然后对所有分量进行特征提取, 并使用支持向量机、随机森林和迭代随机森林方法进行分类。实验结果表明, 迭代随机森林的分类准确率高于支持向量机和随机森林方法。此方法为准确识别癫痫脑电信号提供了一个可行有效的途径, 具有较好的推广和应用价值。

关键词: 脑电信号; 特征提取; 局部均值分解; 迭代随机森林

中图分类号: TP391; O29

文献标识码: A

DOI:10.19292/j.cnki.jdxp.2020.01.009

Classification of EEG Signals Using Local Mean Decomposition and Iterative Random Forest

QIN Xiwen^{a, b}, GUO Yu^a, DONG Xiaogang^a, GUO Jiajing^a, YUAN Di^a

(a. School of Mathematics and Statistics; b. Graduate School, Changchun University of Technology, Changchun 130012, China)

Abstract: In order to achieve effective identification of EEG (Electroencephalogram) signals in patients with epilepsy, improve the quality of life for patients, a method of EEG signal classification based on the combination of local mean decomposition and iterative random forest is proposed for the non-stationary and nonlinear characteristics of EEG signals. Firstly, the EEG signal is decomposed into several product function components and a residual component by using local mean decomposition. Then all components are extracted and classified using support vector machine, random forest and iterative random forest methods. The experimental results show that the classification accuracy of iterative random forest is higher than that of support vector machine and random forest method. This method provides a feasible and effective way to accurately identify epileptic EEG signals, and has good application value.

Key words: electroencephalogram (EEG) signal; feature extraction; local mean decomposition; iterative random forest

0 引言

癫痫是短暂和意外的脑电紊乱, 是一种因脑部损伤而严重影响人类健康的脑部疾病。癫痫发作的迹象不仅可在癫痫患者的大脑中找到, 也可在正常人的大脑中找到^[1]。脑电信号是非线性、非平稳的时序信号, 可通过头皮或颅内电极上的传感器检测, 这些信号是神经元膜电位非常丰富的外部表现^[2]。准确评估、术前评估、癫痫预防以及紧急警报都依赖于癫痫发作的快速检测。医生可通过监测脑电信号评估大脑的状态。因此, 脑电信号在癫痫发作的检测和鉴别中起着重要作用。传统的癫痫检测方法是神经学

收稿日期: 2019-08-28

基金项目: 国家自然科学基金资助项目(11301036); 吉林省教育厅科研基金资助项目(JJKH20170540KJ)

作者简介: 秦喜文(1979—), 男, 吉林梅河口人, 长春工业大学教授, 博士生导师, 主要从事数据分析与统计建模研究, (Tel) 86-13504332781 (E-mail) qinxiwen@ccut.edu.cn; 通讯作者: 董小刚(1961—), 男, 长春人, 长春工业大学教授, 博士生导师, 主要从事高频时间序列研究, (Tel) 86-48043215853 (E-mail) dongxiaogang@mail.ccut.edu.cn。

专家对长期脑电图记录的目视扫描。然而,这是一项耗时的任务,并且由于大量的脑电图数据和不同神经学专家的临床判断标准不同,诊断可能不准确^[3]。因此,开发智能型癫痫自动检测系统显得尤为迫切,具有重要的实际意义。

1875年,英国医生Caton^[4]发现动物大脑存在电活动现象。1934年,经Adrian等^[5]证实,人类的脑电信号获得了世界各国的认同。在此之后,众多学者开始对脑电图进行相关研究,并把这部分知识应用于药理学、生物学和医学等诸多领域。Das等^[6]从经验模态分解和离散小波变换两方面对局灶性和非局灶性脑电图进行了综合分析。Li等^[7]提出了一种基于经验模态分解和支持向量机的癫痫发作期脑电特征提取和模式识别方法。还有一些学者将时频分析与机器学习相结合识别诊断脑电信号,Zhuang等^[8]给出了一种基于经验模态分解(EMD: Empirical Mode Decomposition)的特征提取和脑电信号识别方法;Chen等^[9]提出了一种利用经验模态分解和近似熵的脑电特征提取方法,设计了一种将深度信念网络与支持向量机相结合的分类方法,提取特征向量,识别出人类快乐、平静、悲伤和恐惧4种主要情绪;陆苗等^[10]利用改进的经验模态分解处理脑电信号,用所得固有模态函数(IMF: Intrinsic Mode Function)求取能量熵等特征值提高分类精度;韩敏等^[11]针对单一极限学习机在癫痫脑电信号研究中分类结果不稳定、泛化能力差的缺陷,提出一种基于互信息的AdaBoost极限学习机分类算法。随着计算机科学技术的不断发展,脑电信号的分析方法层出不穷,越来越多样化,陆续出现了非线性分析法^[12]、时频分析法^[13-14]、高阶谱分析法^[15]等系列现代化分析方法^[16]。笔者针对非平稳、非线性的脑电信号,提出一种基于局部均值分解和迭代随机森林相结合的脑电信号分类方法。利用局部均值分解,将脑电信号分解成若干个乘积函数分量和一个残余分量,然后对分解后的所有分量进行特征提取,最后使用随机森林和迭代随机森林等方法进行分类。

1 算法描述

1.1 局部均值分解

局部均值分解(LMD: Local Mean Decomposition)方法可逐步地将调频信号与调幅包络信号分离。通过平滑处理原始信号,将平滑后的信号从原始信号中减去,然后对包络函数进行估计,对结果进行幅度解调实现分离。通过使用由原始信号的连续极值之间的时间延迟加权的移动平均可获得包络估计和原始信号的平滑版本。如果得到的信号不具有平坦包络,则重复该过程,直到获得具有平坦包络的调频信号。然后,从调频信号中计算瞬时频率,将所有包络估计函数相乘得最终包络,将该包络乘以频率调制信号以形成乘积函数,从原始信号中减去该乘积函数,对得到的信号重复整个过程,以产生具有相关包络和瞬时频率的第2乘积函数。继续该分解,直到剩余信号不再包含振荡,得到一个单调函数为止。

LMD算法步骤如下^[17]。

1) 从原信号中记录全部局部极值点 n_i ,对信号中相邻的2个局部极值点取均值

$$m_i = \frac{n_i + n_{i+1}}{2} \quad (1)$$

将所有局部均值 m_i 用直线串联起来,然后利用滑动平均法对局部均值线段进行平滑处理,得局部均值函数 $m_{11}(t)$ 。

2) 利用局部均值点,求出俩相邻极值点之间的包络估计值

$$a_i = |n_i - n_{i+1}|/2 \quad (2)$$

将全部相邻2个包络估计值 a_i 用直线连接,然后采用滑动平均方法进行平滑处理,得包络估计函数 $a_{11}(t)$ 。

3) 将局部均值函数 $m_{11}(t)$ 从原信号 $x(t)$ 中剔除,得

$$h_{11}(t) = x(t) - m_{11}(t) \quad (3)$$

4) 对 $h_{11}(t)$ 进行解调,用 $h_{11}(t)$ 除以包络估计函数 $a_{11}(t)$,得

$$s_{11}(t) = h_{11}(t) / a_{11}(t) \quad (4)$$

计算 $s_{11}(t)$ 的包络估计函数 $a_{12}(t)$,若 $a_{12}(t) \neq 1$,说明 $s_{11}(t)$ 并不是一个纯调频信号,将重复上述解调过

程,直到使 $s_{1n}(t)$ 成为一个纯调频信号为止,即 $-1 \leq S_{1n}(t) \leq 1$,且其包络函数 $a_{1(n+1)}(t) = 1$,有

$$\begin{cases} h_{11}(t) = x(t) - m_{11}(t) \\ h_{12}(t) = s_{11}(t) - m_{12}(t) \\ \vdots \\ h_{1n}(t) = s_{1(n-1)}(t) - m_{1n}(t) \end{cases} \quad (5)$$

其中

$$\begin{cases} s_{11}(t) = h_{11}(t) / a_{11}(t) \\ s_{12}(t) = h_{12}(t) / a_{12}(t) \\ \vdots \\ s_{1n}(t) = h_{1n}(t) / a_{1n}(t) \end{cases} \quad (6)$$

迭代终止条件为

$$\lim_{n \rightarrow \infty} a_{1n}(t) = 1 \quad (7)$$

但在实际问题中,迭代处理至 $\lim_{n \rightarrow \infty} a_{1n}(t) = 1$ 是无法实现的。为此,想要得到一个较为理想的纯调频信号,设定一个符合实际情况的迭代终止条件

$$a_{1n}(t) \approx 1 \quad (8)$$

5) 在上述迭代过程中,将求得的所有包络估计函数相乘,得包络信号

$$a_1(t) = a_{11}(t) a_{12}(t) \cdots a_{1n}(t) = \prod_{q=1}^n a_{1q}(t) \quad (9)$$

6) 用包络信号 $a_1(t)$ 和纯调频信号 $s_{1n}(t)$ 相乘,可得原信号的乘积函数(PF: Product Function)

$$P_1(t) = a_1(t) s_{1n}(t) \quad (10)$$

7) 将一个分量 $P_1(t)$ 从原信号 $x(t)$ 中剔除,获得一个全新的信号 $u_1(t)$,再将 $u_1(t)$ 作为原始数据重复上述步骤,循环 k 次,直到 u_k 为一个单调函数为止

$$\begin{cases} u_1(t) = x(t) - P_1(t) \\ u_2(t) = u_1(t) - P_2(t) \\ \vdots \\ u_k(t) = u_{k-1}(t) - P_k(t) \end{cases} \quad (11)$$

所有的乘积函数分量和 u_k 重组,可求出原始信号

$$x(t) = \sum_{i=1}^k P_i(t) + u_k(t) \quad (12)$$

这说明 LMD 分解没有造成原信号的丢失。

1.2 特征提取

对局部均值分解后得到的各阶乘积函数提取重要特征,其中包括均值、标准差等一系列简单统计量,以及能量熵和信息熵。

1.2.1 变异系数

变异系数(CV: Coefficient of Variation)是衡量资料中各观测值变异程度的统计量,为标准差与平均数的比值

$$C = \sigma / \mu \quad (13)$$

其中

$$\mu_i = \frac{1}{l} \sum_{t=1}^l |P_i(t)|, \quad \sigma_i = \sqrt{\frac{1}{l} \sum_{t=1}^l \left(P_i(t) - \frac{1}{l} \sum_{t=1}^l P_i(t) \right)^2}$$

其中 l 为数据长度,即分解后的乘积函数长度。

1.2.2 波动指数

波动指数是描述信号波动幅度大小的一个统计量,在实验中可见癫痫发作间期信号的波动剧烈程度

小于发作期,且相对稳定。其定义为

$$F_i = \frac{1}{l} \sum_{t=1}^l |P_i(t) - P_i(t+1)| \quad (14)$$

1.2.3 能量熵

在不同状态下,脑电振动信号的频率分布会发生变化,故癫痫发作期与发作间期脑电信号的能量也会发生变化。一般情况下,发作间期脑电信号中的能量分布是均匀的、不确定的,因而大于癫痫发作期脑电信号。因此可用 LMD 能量熵判断患者是否处于癫痫状态。

乘积函数分量的能量熵通过以下步骤计算^[18]。首先,计算第 i 个 PF 的能量

$$E_i = \int_{t_1}^{t_2} c_i^2(t) dt \quad (15)$$

其中 t_1 和 t_2 分别为信号开始和结束时间。之后计算整个 PF 的能量

$$E = \sum_{i=1}^n E_i \quad (16)$$

最后,定义整个 PF 的能量熵为

$$H_{en} = - \sum_{i=1}^n P_i \log_2 P_i \quad (17)$$

1.2.4 信息熵

信息熵是一个数学的抽象概念,是为了消除数据不确定性的度量。癫痫发作期信号的信息熵通常比发作间期的信息熵低。其定义为

$$H(x) = E[I(x)] = E[\log_2(1/p(x))] = - \sum p(x_i) \log_2(p(x_i)), \quad i = 1, \dots, n \quad (18)$$

其中 x 表示随机变量,与之相对应的是所有可能输出的集合,定义为符号集; $p(x)$ 表示输出概率函数。变量的不确定性越大,熵也就越大。

利用 LMD 分解波恩癫痫研究中心数据库中癫痫发作间期与发作期数据,计算分解后乘积函数的特征值。

1.3 迭代随机森林

迭代随机森林(iRF: iterative Random Forest)在随机森林的基础上通过对选定的特征进行迭代重新赋权(iterative re-weighting),得到一个带有特征权重的随机森林,然后将泛化的随机交叉树作用于带有特征权重的随机森林上,识别特征的高阶交互作用,保证其具有较高的预测能力。迭代随机森林的具体工作流程如下^[18]。

1) 对随机森林进行迭代重新赋权,给定迭代次数 K ,在数据集 D 上,通过迭代生成 K 个具有特征权重的随机森林,记为 $RF(\omega^k)$, $k=1, \dots, K$ 。初始权重 $k=1$ 时, $\omega = (1/p, \dots, 1/p)$,并计算 p 个特征的重要性,即基尼纯度的平均减少,记为 $v^{(1)} = (v_1, \dots, v_p)$ 。令 $\omega^{(k)} = v^{(k-1)}$,即用随机森林特征的重要性作为其权重。

2) 将泛化的随机交叉树作用于 $RF(\omega^k)$,产生一组交叉作用集 S 。

3) 计算 Bagged 稳定得分,使用“外层”(out layer)自助法,以评价重现交叉作用的稳定性。生成自助抽样数据集 $D_{(b)}$, $b=1, \dots, B$,在 $D_{(b)}$ 上拟合随机森林 $RF(\omega^k)$,并且使用泛化随机交叉树识别交互作用集 $S_{(b)}$,给出交叉作用集 S 的稳定分数公式

$$F(S) = \frac{1}{B} \sum_{b=1}^B I(S \in S_{(b)}) \quad (19)$$

表示交互作用出现次数的比例。其中 $S \in \bigcup_{b=1}^B S_{(b)}$ 。

2 实验结果

2.1 脑电信号分解

实验数据取自德国波恩大学癫痫研究中心数据库。该数据库是目前癫痫脑电信号研究最为普遍采用的脑电数据库,其中包含 5 个子集,分别标号为 A、B、C、D、E。每个子集包含 100 个实验样本,每个样本

采样时间为 23.6 s、频率为 173.61 Hz, 每个样本信号包含 4 097 个样本点。笔者选取数据库中数据集 D 和数据集 E, 分为癫痫发作间期和发作期进行分析。图 1 给出了发作间期与发作期的原始癫痫脑电信号。




图 1 癫痫发作间期和癫痫发作期的样本

Fig. 1 The sample of ictal and interictal EEG

图 1a 为一组癫痫发作间期的脑电信号样本, 可见其信号波动程度较大, 但具有一定的规律性。图 1b 为一组癫痫发作期的脑电信号样本, 可见该信号波幅较小, 且不稳定。由图 1 可知, 两种脑电信号在波动幅度和稳定性方面具有明显差异。

图 2 和图 3 给出了 LMD 分解后癫痫发作期和发作间期的脑电信号 PF 分量。癫痫发作间期脑电信号经 LMD 分解后得到 4 个乘积函数和 1 个残余分量(见图 2); 癫痫发作期脑电信号经 LMD 分解后得到 4 个乘积函数和 1 个残余分量(见图 3)。




图 2 发作间期 EEG 分解后的 PF 分量

Fig. 2 PF of EEG after decomposition
in interictal period




图 3 发作期 EEG 分解后的 PF 分量

Fig. 3 PF of EEG after decomposition
in ictal period

2.2 脑电信号特征提取

对癫痫脑电信号发作间期和发作期的 200 个样本信号, 经过局部均值分解后提取所有乘积函数的特

征向量。表 1 为癫痫脑电信号发作间期的特征样本,表 2 为癫痫脑电信号发作期的特征样本。

表 1 癫痫脑电信号发作间期特征样本

Tab. 1 The sample of interictal EEG features

PF	均值	标准差	极差	变异系数	波动指数	能量熵	信息熵
PF1	-11.72	119.42	683.36	-10.18	0.052 3	0.28	25.79
PF2	0.98	50.44	414.83	51.27	0.022 8	2.77	23.32
PF3	0.28	19.98	101.27	71.50	0.002 3	5.43	20.64
PF4	0.32	8.17	34.67	25.54	0.000 7	8.01	18.06
Residual	4.34	5.52	22.45	1.27	-0.003 9	9.15	16.93

表 2 癫痫脑电信号发作期特征样本

Tab. 2 The sample of ictal EEG features

PF	均值	标准差	极差	变异系数	波动指数	能量熵	信息熵
PF1	-0.05	35.37	318.31	-634.94	0.004 3	0.79	22.29
PF2	0.85	24.36	148.71	28.50	0.000 4	1.86	21.21
PF3	0.09	16.51	86.57	171.58	-0.004 4	2.99	20.09
PF4	-0.08	5.78	26.33	-68.34	0.002 2	6.01	17.06
Residual	-53.25	3.04	9.83	0.057	0.000 6	7.86	15.21

2.3 癫痫脑电信号分类结果

笔者分别选取支持向量机、随机森林及迭代随机森林 3 种机器学习方法对局部均值分解后所求特征向量进行分类,并比较分类结果(见表 3)。实验样本共 1 284 个,选取 900 个作为训练集,另外 384 个作为测试集,结果表明,LMD 与迭代随机森林相结合的算法对癫痫发作间期和发作期 EEG 的乘积函数分类效果最佳,正确识别率为 98.177%。

表 3 癫痫脑电信号分类结果比较

Tab. 3 The compare of EEG classification result

癫痫状态	样本量	LMD-SVM		LMD-RF		LMD-iRF	
		错误样本/个	准确率/%	错误样本/个	准确率/%	错误样本/个	准确率/%
癫痫发作间期	190	1	99.477	10	94.737	7	96.316
癫痫发作期	194	10	94.846	0	100	0	100
总体统计	384	11	97.136	10	97.395	7	98.177

3 讨 论

在临床医学上,癫痫脑电信号的自动检测和分类有着重要意义。Zhang 等^[19]提出了一种基于 LMD 和 SVM 结合的脑电信号分类方法,证明了在诊断脑电信号方面,脑电信号自适应分解与机器学习相结合的全新算法具有可行性和有效性。

在处理非平稳和非线性信号时,LMD 相对于其他时频分析方法具有很多优势。LMD 采用平滑处理的方法形成局部均值函数和局部包络函数,这既保持了 EMD 分解的优势,又可避免像 EMD 分解中采用 3 次样条函数形成上下包络时产生的过包络、欠包络现象,此外 LMD 端点效应的扩散程度远小于 EMD。此方法除了分解脑电信号,还可应用于其他领域,如机械故障、金融股市和环境质量等。在目前众多分类算法中,iRF 不仅具有和 RF 一样的抗噪音和抗干扰能力,且经过多次迭代赋权,可充分利用每棵树的分类能力,使整体分类效果得到提升。

通过对德国波恩大学癫痫研究中心的脑电数据进行实验分析,将局部均值分解方法的自适应分解特性与迭代随机森林的多次赋权相结合,使 LMD-iRF 算法分类结果的准确率高于 LMD-SVM 和 LMD-RF 算法。此方法不仅可用于生物医学信号分析处理,还可应用在环境监测、机械故障诊断和金融分析等领域,是一种具有较高精度的分类算法。

4 结 语

笔者利用局部均值分解处理癫痫脑电信号,并对分解的信号进行特征提取,再对所提取特征使用迭代随机森林方法进行分类,完成对癫痫脑电信号的自动检测。实验结果表明,该方法可对癫痫发作期和发作间期的脑信号准确分类,分类准确度高达 98.177%,为癫痫的快速准确检测奠定了良好的基础。

参考文献:

- [1] 张涛,陈万忠,李明阳. 基于 AdaBoost 算法的癫痫脑电信号识别 [J]. 物理学报, 2015, 64(12): 1-7.
ZHANG Tao, CHEN Wanzhong, LI Mingyang. Recognition of Epilepsy Electroencephalography Based on AdaBoost Algorithm [J]. Acta Physica Sinica, 2015, 64(12): 1-7.
- [2] 校午阳,郑旭媛. 基于匹配追踪的癫痫脑电信号的时频分析 [J]. 国际生物医学工程杂志, 2012, 35(1): 8-14.
XIAO Wuyang, ZHENG Xuyuan. Time-Frequency Analysis Based on Matching Pursuit and Its Application in Epilepsy EEG [J]. International Journal of Biomedical Engineering, 2012, 35(1): 8-14.
- [3] 张涛,陈万忠,李明阳. 基于频率切片小波变换和支持向量机的癫痫脑电信号自动检测 [J]. 物理学报, 2016, 65(3): 411-417.
ZHANG Tao, CHEN Wanzhong, LI Mingyang. Automatic Seizure Detection of Electroencephalogram Signals Based on Frequency Slice Wavelet Transform and Support Vector Machine [J]. Acta Physica Sinica, 2016, 65(3): 411-417.
- [4] CATON R. Electrical Currents of the Brain [J]. Journal of Nervous and Mental Disease, 1875, 2(4): 610.
- [5] ADRIAN E D, MATTHEWS B H C. The Berger Rhythm: Potential Changes from the Occipital Lobes in Man [J]. Brain, 1934: 57(4): 355-385.
- [6] DAS A B, BHUIYAN M I H. Discrimination and Classification of Focal and Non-Focal EEG Signals Using Entropy-Based Features in the EMD-DWT Domain [J]. Biomedical Signal Processing and Control, 2016, 29: 11-21.
- [7] LI S, ZHOU W, YUAN Q, et al. Feature Extraction and Recognition of Ictal EEG Using EMD and SVM [J]. Computers in Biology and Medicine, 2013, 43(7): 807-816.
- [8] ZHUANG Ning, ZENG Ying, TONG Li, et al. Emotion Recognition from EEG Signals Using Multidimensional Information in EMD Domain [J/OL]. (2017-08-16). [2019-07-08]. <https://www.hindawi.com/journals/bmri/2017/8317357/>.
- [9] CHEN T, JU S, YUAN X, et al. Emotion Recognition Using Empirical Mode Decomposition and Approximation Entropy [J]. Computers & Electrical Engineering, 2018, 72: 383-392.
- [10] 陆苗,邹俊忠,张见,等. 基于 IMF 能量熵的脑电情感特征提取研究 [J]. 生物医学工程研究, 2016, 35(2): 71-74.
LU Miao, ZOU Junzhong, ZHANG Jian, et al. Emotion Electroencephalograph (EEG) Recognition Based on IMF Energy Entropy [J]. Journal of Biomedical Engineering Research, 2016, 35(2): 71-74.
- [11] 韩敏,孙卓然. 基于小波变换和 Adaboost 极限学习机的癫痫脑电信号分类 [J]. 计算机应用, 2015, 35(9): 2701-2706.
HAN Min, SUN Zhuoran. Epileptic EEG Signals Classification Based on Wavelet Transform and AdaBoost Extreme Learning Machine [J]. Journal of Computer Applications, 2015, 35(9): 2701-2706.
- [12] 李营,吕兆承. 基于 EEMD 算法的癫痫脑电信号识别 [J]. 重庆工商大学学报: 自然科学版, 2014, 31(5): 90-94.
LI Ying, LÜ Zhaocheng. Epileptic EEG Signal Identification Based on EEMD [J]. Journal of Chongqing University of Industry and Commerce: Natural Science Edition, 2014, 31(5): 90-94.
- [13] 秦喜文,周明眉,董小刚,等. 基于 EMD 的中国股票市场分形特征研究 [J]. 吉林大学学报: 信息科学版, 2016, 34(3): 449-454.
QIN Xiwen, ZHOU Mingmei, DONG Xiaogang, et al. Research on Fractal Characteristics of Chinese Stock Market Based on EMD [J]. Journal of Jilin University: Information Science Edition, 2016, 34(3): 449-454.
- [14] 汤伟,陶倩,陈景霞,等. 一种基于 S 变换及样本熵组合特征的癫痫脑电信号分类方法 [J]. 科学技术与工程, 2018, 18(27): 157-161.
TANG Wei, TAO Qian, CHEN Jingxia, et al. An Epileptic Electroencephalogram Signal Classification Method Based on Combination Feature of S Transform and Sample Entropy [J]. Journal of Science and Technology and Engineering, 2018, 18(27): 157-161.
- [15] 王海玉,胡剑锋,王映龙. 脑电信号处理方法的研究综述 [J]. 计算机时代, 2018, 4(1): 13-15.

- WANG Haiyu , HU Jianfeng , WANG Yinglong. A Review of EEG Signal Processing Methods [J]. Journal of the Computer Age ,2018 ,4(1) : 13-15.
- [16]ISAAC FERNÁNDEZ-VARELA , ELENA HERNÁNDEZ-PEREIRA , DIEGOÁLVAREZ-ESTÉVEZ , et al. Combining Machine Learning Models for the Automatic Detection of EEG Arousals [J]. Neurocomputing ,2017 ,268: 100-108.
- [17]SMITH J S. The Local Mean Decomposition and Its Application to EEG Perception Data [J]. Journal of the Royal Society Interface ,2005 ,2(5) : 443-454.
- [18]BASU S , KUMBIER K , BROWN J B , et al. Iterative Random Forests to Detect Predictive and Stable High-Order Interactions [J]. Proc Natl Acad Sci USA ,2017 ,115(8) : 1943-1948.
- [19]ZHANG T , CHEN W. LMD Based Features for the Automatic Seizure Detection of EEG Signals Using SVM [J]. IEEE Transactions on Neural Systems and Rehabilitation Engineering ,2016 ,25(8) : 1100-1108.

(责任编辑: 刘俏亮)